



DeepL

Subscribe to DeepL Pro to translate larger documents.
Visit www.DeepL.com/pro for more information.

机器学习入门

机器学习（双语）

齐飞 (Fei **Qi**) xfred.qi@ieee.org

李阳 (Yang **Li**)

2024年2月

人工智能学院






机器学习基本概念机器学习算法类型机器学习问题

总结

机器学习基础概念

机器学习 (**Samuel 1959**) 指使计算机无需显式编程即可学习的能力的研究领域。






良好定义的学习问题（**Mitchell 1998**）若计算机程序在经验 $\mathbf{E}$ 中针对任务 T 和性能度量 $\mathbf{P}$ 进行学习，且其在 P 度量下的 T 任务表现随经验 E 提升，则称该程序从经验 $\mathbf{E}$ 中学习。




假设某邮件程序能记录用户是否将邮件标记为垃圾邮件，并通过学习这些数据来更有效地过滤垃圾邮件。在此问题中，任务 T 是什么？


- 将邮件分类为垃圾邮件或非垃圾邮件
- 记录用户对邮件标记为垃圾邮件或非垃圾邮件的行为
- 正确分类为垃圾邮件或非垃圾邮件的邮件数量（或比例）
- 以上皆非：这并非机器学习问题





(班科与布里尔出版社，2001年)



(班科与布里尔 2001)





(班科与布里尔 2001)

“胜者并非拥有最佳算法者，而是掌握最多数据者。”

机器学习算法类型



- 监督学习
- 无监督学习
- 强化学习
- 推荐系统



监督学习涉及使用已知的“正确答案”

回归预测连续变量作为输出

分类预测离散变量作为输出（如0和1）



监督学习涉及使用已知的“正确答案”

回归预测连续变量作为输出

分类预测离散变量作为输出（如0和1）

房价预测




监督学习涉及使用已知的“正确答案”

回归预测连续变量作为输出

分类预测离散变量作为输出（如0和1）

房价预测

肿瘤诊断/癌症预测





P1: 针对多个产品及其下属的众多商品，目标是预测这些产品未来三个月的销售量。

P2: 使用软件检查客户账户，每个账户需判定是否存在被黑客入侵或资金挪用情况。


上述两个问题中，哪些属于回归问题或分类问题：

- 两者均为分类问题。
- P1是分类问题，P2是回归问题。
- P1是回归问题，P2是分类问题。
- 两者均为回归问题。



聚类

概率密度估计维数缩减/可视化







在以下示例中，哪些会使用无监督学习技术来解决？

- 给定电子邮件及其标注的垃圾邮件属性，学习构建垃圾邮件过滤器。
- 根据从网络获取的新闻集，根据其是否涉及同一事件进行分类。
- 基于客户数据数据库，自动发现市场细分并将其划分为相关市场分群。
- 基于诊断患者是否患有糖尿病的数据库，学习诊断新患者的糖尿病状况。

机器学习问题






- 训练集包含关于 x 的 N 个观测值, $\mathbf{x}$

$$p\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\mathbf{q}^T$$

- 对应的目标函数值 $\mathbf{t}$ 为

$$\mathbf{t} = p\mathbf{t}_1, \mathbf{t}_2, \dots, \mathbf{t}_N\mathbf{q}^T$$




- 训练集包含关于 x 的 N 个观测值, $\mathbf{x}$


$$[x_1, x_2, \dots, x_N]^T$$


- 对应的目标函数值 $\mathbf{t}$ 为


$$\mathbf{t} = [t_1, t_2, \dots, t_N]^T$$


$$\mathbf{w} = \begin{bmatrix} w_0 \\ w_1 \\ w_2 \end{bmatrix}, \quad \mathbf{x}^M = \begin{bmatrix} 1 \\ x \\ x^2 \end{bmatrix}$$




























	$M = 0$	$M = 1$	$M = 3$	$M = 9$
w_0^*	0.19	0.82	0.31	0.35
w_1^*		-1.27	7.99	232.37
w_2^*			-25.43	-5321.83
w_3^*			17.37	48568.31
w_4^*				-231639.30
w_5^*				640042.26
w_6^*				-1061800.52
w_7^*				1042400.18
w_8^*				-557682.99
w_9^*				125201.43



$$E_{\text{pwq}} = \frac{1}{2} \sum_{n=1}^N r y p x, w q - t s^2 + \frac{\lambda}{2} \{ \mathbf{w} \}^2$$









	$\ln \lambda = -\infty$	$\ln \lambda = -18$	$\ln \lambda = 0$
w_0^*	0.35	0.35	0.13
w_1^*	232.37	4.74	-0.05
w_2^*	-5321.83	-0.77	-0.06
w_3^*	48568.31	-31.97	-0.05
w_4^*	-231639.30	-3.89	-0.03
w_5^*	640042.26	55.28	-0.02
w_6^*	-1061800.52	41.32	-0.01
w_7^*	1042400.18	-45.95	-0.00
w_8^*	-557682.99	-91.53	0.00
w_9^*	125201.43	72.68	0.01

摘要



机器学习的定义：监督学习与无监督学习

- 回归/分类
- 聚类/降维/可视化

模型阶数与正则化

- 过拟合
- 正则化



 班科, 米歇尔与埃里克·布里尔 (2001年7月6日)。《自然语言消歧的超大规模语料扩展研究》。载于: 第39届计算语言学协会年会论文集。ACL '01。美国: ACL, 第26-33页。 DOI: 10.3115/1073012.1073017.

 Mitchell, Tom (1998). **《机器学习》**. McGraw Hill.

 塞缪尔, A. L. (1959年7月)。《基于跳棋游戏的机器学习研究》。载于: *IBM 研究与开发期刊* 第3卷第3期, 第210-229页。国际标准期刊号: 0018-8646。数字对象唯一标识符: 10.1147/rd.33.0210。