

线性模型：回归

机器学习（双语）

齐飞 (Fei **Qi**) xfred.qi@ieee.org

李阳 (Yang **Li**)

2024年3月

人工智能学院

西安电子科技大学





单变量线性回归 多变量线性回归

特征与广义线性回归正则化

贝叶斯线性回归

单变量线性回归



监督学习

给定数据中每个实例的“正确答案”。



监督学习

给定数据中每个实例的“正确答案”。

回归

用于预测实数值输出。




监督学习

为数据中的每个实例提供“正确答案”。

回归

用于预测实数值输出。

智能手机价格预测






监督学习

数据中每个实例都给出“正确答案”。

回归

预测实数值输出。

智能手机价格预测





手机价格训练集

显示屏尺寸 (x)	价格 (美元) (y)
4.6	627.7
4.7	829.6
5	748.9
6.4	989.1
4.4	685.6
.	.



手机价格训练集

显示屏尺寸 (x)	价格 (美元) (y)
4.6	627.7
4.7	829.6
5	748.9
6.4	989.1
4.4	685.6
.	.

符号

- m 训练样本数量
- x 输入变量/特征
- y 输出变量



手机价格训练集

显示尺寸 (x)	价格 (美元) (y)
4.6	627.7
4.7	829.6
5	748.9
6.4	989.1
4.4	685.6
.	.

符号


- m 训练样本数量
- x 输入变量/特征
- y 输出变量


- $x^{p1q} \quad 4.6, y^{p1q} \quad 627.7$

- $x^{p2q} \quad 4.7, y^{p2q} \quad 829.6$


-


- x^{pmq}, y^{pmq}






我们如何表示 h ?





如何表示h?



● 单变量回归

● 单变量回归



手机价格训练集

显示屏尺寸 (x)	价格 (美元) (y)
4.6	627.7
4.7	829.6
5	748.9
6.4	989.1
4.4	685.6
.	.



手机价格训练集

显示屏尺寸 (x)	价格 (美元) (y)
4.6	627.7
4.7	829.6
5	748.9
6.4	989.1
4.4	685.6
.	.

- 假设: h_w
 - w_i 's: 参数
 - 如何选择 w_i 's?
- w_0 $w_1 x$



- 假设

$$h_{\mathbf{w}}(\mathbf{x}) = w_0 + w_1 x$$

- 参数 w_0, w_1

- 成本函数

$$J(\mathbf{w}) = \frac{1}{2m} \sum_{i=1}^m (h_{\mathbf{w}}(\mathbf{x}^{(i)}) - y^{(i)})^2$$


- 目标

$$\arg \min_{\mathbf{w}} J(\mathbf{w})$$



$$h_w \text{ } \mathbf{p} \times \mathbf{q}$$


对于固定的 w_0, w_1 , 这是 x 的函数。





$$h_w^T x$$


对于固定的 w_0 、 w_1 ，这是 x 的函数。





$$h_w^T \mathbf{x}$$


对于固定的 w_0, w_1 ，这是 x 的函数。






$$h_w^T x$$

对于固定的 w_0, w_1 ，这是 x 的函数。



$$J(w_0, w_1)$$

参数 w_0, w_1 的函数。





- 设函数 $J(w_0, w_1; q)$
- 求 $\arg \min_{w_0, w_1} J(w_0, w_1; q)$



- 有函数 $J(w_0, w_1; q)$
- 求 $\arg \min_{w_0, w_1} J(w_0, w_1; q)$

大纲

- 从 w_0, w_1 开始
- 持续调整 w_0, w_1 以减少 $J(w_0, w_1; q)$
- 直至达到最小值



重复直至收敛 {

$$w_j := w_j - \alpha \sum_{i=1}^n \frac{\partial}{\partial w_j} J(w_0, w_1, \dots, w_n) \quad (\text{当 } j = 0 \text{ 且 } j = 1)$$

}

α : 学习率



重复直至收敛 {

$$w_j : w_j \leftarrow w_j - \alpha \frac{\partial J(w_0, w_1)}{\partial w_j} \quad (\text{当 } j = 0 \text{ 且 } j = 1)$$

}

α : 学习率

● 同时更新

$$\begin{aligned} \text{temp0} &: w_0 - \alpha \frac{\partial J(w_0, w_1)}{\partial w_0} \\ \text{temp1} &: w_1 - \alpha \frac{\partial J(w_0, w_1)}{\partial w_1} \\ w_0 &: \text{temp0} \\ w_1 &: \text{temp1} \end{aligned}$$



重复直至收敛 {

$w_j := w_j - \alpha \frac{\partial J(w_0, w_1)}{\partial w_j} q$ (当 $j = 0$ 且 $j = 1$)
}

α : 学习率

同时更新

temp0 : $w_0 - \alpha \frac{\partial J(w_0, w_1)}{\partial w_0} q$
temp1 : $w_1 - \alpha \frac{\partial J(w_0, w_1)}{\partial w_1} q$
 $w_0 := temp0$
 $w_1 := temp1$

错误

temp0 : $w_0 - \alpha \frac{\partial J(w_0, w_1)}{\partial w_0} q$
 $w_0 := temp0$
temp1 : $w_1 - \alpha \frac{\partial J(w_0, w_1)}{\partial w_1} q$
 $w_1 := temp1$



梯度下降可能收敛到局部极小值，即使学习率 α 固定也是如此。



梯度下降可能收敛到局部极小值，即使学习率 α 固定也是如此。

当接近局部极小值时，梯度下降法会自动采取更小的步长。因此无需随时间推移降低 α 值。



即使保持学习率 α 不变，梯度下降仍可能收敛于局部极小值

。

当接近局部极小值时，梯度下降法会自动减小步长。因此无需

随时间递减 α 。

梯度下降算法

重复直至收敛 $\{w_j : w_j \leftarrow w_j - \alpha \nabla J(w_j) \mid j = 0, 1, \dots, n-1\}$ (

当 $j \neq 0$ 且 $j \neq 1$)

$\nabla J(w_j)$

}



梯度下降法即使在学习率 α 固定的情况下，也可能收敛到局部最优解。

当接近局部极小值时，梯度下降法会自动减小步长。因此无需随时间降低 α 值。

梯度下降算法

重复直至收敛 {

$$w_j := w_j - \alpha \frac{\partial}{\partial w_j} J(w_0, w_1)$$

(用 $j = 0$ 且 $j = 1$)

于

}

线性回归模型

$$h_w(x) = w_0 + w_1 x$$

$$J(w_0, w_1) = \frac{1}{2} \sum_{i=1}^m (h_w(x^{(i)}) - y^{(i)})^2$$



$$\frac{\partial J(p, w)}{\partial w_j} = \frac{1}{2m} \sum_{i=1}^m (w_0 + w_1 x_i^{(j)} + \dots + w_n x_i^{(n)} - y_i)^2$$



重复直至收敛 {

$$w_0 : w_0 \quad \alpha \frac{1}{m} \sum_{i=1}^m h_w(x^{piq}) - y^{piq}$$


$$w_1 : w_1 \quad \alpha \frac{1}{m} \sum_{i=1}^m h_w(x^{piq}) - y^{piq} x^{piq}$$

}




$$h_w p x q$$

对于固定的 w_0, w_1 , 这是 x 的函数。



$$J(p w_0, w_1) q$$


参数 w_0, w_1 的函数。






$$h_w p x q$$

对于固定的 w_0, w_1 ，这是 x 的函数。



$$J(p w_0, w_1) q$$


参数 w_0, w_1 的函数。






$$h_w p x q$$

对于固定的 w_0, w_1 ，这是 x 的函数。



$$J(pw_0, w_1) q$$


参数 w_0, w_1 的功能。






$$h_w p x q$$

对于固定的 w_0, w_1 ，这是 x 的函数。



$$J(pw_0, w_1) q$$


参数 w_0, w_1 的函数。






$$h_w p x q$$

对于固定的 w_0, w_1 ，这是 x 的函数。



$$J(pw_0, w_1) q$$


参数 w_0, w_1 的函数。






$$h_w p x q$$

对于固定的 w_0, w_1 ，这是 x 的函数。



$$J(pw_0, w_1) q$$


参数 w_0, w_1 的函数。






$$h_w p x q$$

对于固定的 w_0, w_1 ，这是 x 的函数。



$$J(p w_0, w_1) q$$


参数 w_0, w_1 的函数。






$$h_w p x q$$

对于固定的 w_0, w_1 ，这是 x 的函数。



$$J(p w_0, w_1) q$$


参数 w_0, w_1 的函数。






$$h_w p x q$$

对于固定的 w_0, w_1 ，这是 x 的函数。



$$J(pw_0, w_1) q$$

参数 w_0, w_1 的函数。



多元线性回归



手机价格训练集

显示屏尺寸	价格（美元）
x	y
3.6	499.7
4.1	570.5
4.2	551.9
5.5	918.9
6.2	980
.	.



手机价格训练集

显示屏尺寸	价格（美元）
x	y
3.6	499.7
4.1	570.5
4.2	551.9
5.5	918.9
6.2	980
.	.

假设

$$h_w = w_0 + w_1 x$$

成本函数

$$J(w_0, w_1) = \frac{1}{2m} \sum_{i=1}^m (h_w^{(i)} - y^{(i)})^2$$

目标

$$\arg \min_{w_0, w_1} J(w_0, w_1)$$

梯度下降

重复直至收敛 {

$$w_j = w_j - \alpha \frac{\partial}{\partial w_j} J(w_0, w_1), j=0, 1$$



显示尺寸	CPU	内存	使用年 限	价格（美元）
x_1	x_2	x_3	x_4	y
4.1	1.1	24	3.5	570.5
5.5	1.2	2	1	918.9
6.2	1.2	26	2	980
.	.	.	.	.

注释：

- n 特征数量。
- $x^{(i)}$ 第 i 个训练样本的输入（特征）。



- $x_j^{(i)}$ 第*i*个训练样本中第*j*个特征的值。



- 先前

$$h_w = \text{pxq}_{w_0 w_1 x}$$



- 先前

$$h_w = w_0 + w_1 x$$

- 针对新手机价格数据集

$$h_w = w_0 + w_1 x_1 + w_2 x_2 + w_3 x_3 + w_4 x_4$$



- 先前

$$h_w = w_0 + w_1 x$$

- 针对新手机价格数据集

$$h_w = w_0 + w_1 x_1 + w_2 x_2 + w_3 x_3 + w_4 x_4$$

- 示例：

$$h_w = 100 + 0.2x_1 + 1.2x_2 + 0.01x_3 + 0.5x_4$$



$$h_w = \sum_{i=0}^n w_i x_i = w_0 + w_1 x_1 + w_2 x_2 + \dots + w_n x_n$$



$$h_{\mathbf{w}} \mathbf{p} \times \mathbf{q} = w_0 + w_1 x_1 + w_2 x_2 + \dots + w_n x_n$$

- 为便于记号，定义 $x_{(0)} = 1$ ($x^{p \approx (i) = (q) = 1}$)。

$$\mathbf{x} = \begin{pmatrix} x_0 \\ x_1 \\ \vdots \\ x_n \end{pmatrix} \in \mathbb{R}^{n+1} \quad \mathbf{w} = \begin{pmatrix} w_0 \\ w_1 \\ \vdots \\ w_n \end{pmatrix} \in \mathbb{R}^{n+1}$$



$$h_{\mathbf{w}}(\mathbf{x}) = w_0 + w_1 x_1 + w_2 x_2 + \dots + w_n x_n$$

- 为便于记号，定义 $x_{(0)} = 1$ ($x^{(p)}_{(i)} = x^{(q)}_{(i)}$)。

$$\mathbf{x} = \begin{bmatrix} x_0 \\ x_1 \\ \vdots \\ x_n \end{bmatrix} \in \mathbb{R}^{n+1}, \quad \mathbf{w} = \begin{bmatrix} w_0 \\ w_1 \\ \vdots \\ w_n \end{bmatrix} \in \mathbb{R}^{n+1}$$

$$h_{\mathbf{w}}(\mathbf{x}) = w_0 + w_1 x_1 + w_2 x_2 + \dots + w_n x_n = \mathbf{w}^T \mathbf{x}$$

- 多元线性回归



- 假设 (参数 $w = w_0, w_1, w_2, \dots, w_n$)。

$$h_w(x) = w_0 + w_1 x_1 + w_2 x_2 + \dots + w_n x_n$$



- 假设 (参数 $w = w_0, w_1, w_2, \dots, w_n$)。

$$h_w(x) = w_0 + w_1 x_1 + w_2 x_2 + \dots + w_n x_n = \mathbf{w}^T \mathbf{x}$$

- 成本函数

$$J(w) = \frac{1}{2m} \sum_{i=1}^m (y_i - h_w(x_i))^2 = \frac{1}{2m} \sum_{i=1}^m (y_i - \mathbf{w}^T \mathbf{x}_i)^2$$



- 假设 (参数 $w = w_0, w_1, w_2, \dots, w_n$)。

$$h_{\mathbf{w}}(\mathbf{x}) = w_0 + w_1 x_1 + w_2 x_2 + \dots + w_n x_n$$

- 成本函数

$$J(\mathbf{w}) = \frac{1}{2m} \sum_{i=1}^m (h_{\mathbf{w}}(\mathbf{x}^{(i)}) - y^{(i)})^2$$

- 梯度下降

重复直至收敛 {

$$\mathbf{w}_j := \mathbf{w}_j - \alpha \frac{\partial}{\partial \mathbf{w}_j} J(\mathbf{w})$$

(同时更新所有 $j = 0, 1, 2, \dots, n$)
}



先前 (n-1)

重复 {

$$w_0 : w_0 \quad w_1 : \alpha \frac{1}{m} \sum_{i=1}^m h_w(x^{piq}) - y^{piq}$$

$$w_1 : \alpha \frac{1}{m} \sum_{i=1}^m h_w(x^{piq}) - y^{piq} - x^{piq}$$

}



先前 (n

1

) 重复{

$$w_0 : w_0 \quad \alpha \frac{1}{m} \sum_{i=1}^m h_w x^{piq} - y^{piq}$$

$$w_1 : w_1 \quad \alpha \frac{1}{m} \sum_{i=1}^m h_w x^{piq} - y^{piq} x^{piq}$$

}

新算法 (n1)

重复 {

$$w_j : w_j \quad \alpha \frac{1}{m} \sum_{i=1}^m h_w x^{piq} - y^{piq} x^{piq}_j$$

}



先前 (n-1)

重复 {

$$w_0 : w_0 \quad \alpha \frac{1}{m} \sum_{i=1}^m h_w x^{piq} - y^{piq}$$

$$w_1 : w_1 \quad \alpha \frac{1}{m} \sum_{i=1}^m h_w x^{piq} - y^{piq} x^{piq}$$

}

新算法 (n1)

重复 {

$$w_j : w_j \quad \alpha \frac{1}{m} \sum_{i=1}^m h_w x^{piq} - y^{piq} x^{piq}_j$$

}

$$\frac{B}{Bw_j} \quad p q$$



	显示尺寸	CPU	内存	年龄	价格 (美元)
x_0	x_1	x_2	x_3	x_4	y
1	4.1	1.1	24	3.5	570.5
1	5.5	1.2	2	1	918.9
1	6.2	1.2	26	2	980
.	.	.	.	.	.



	显示尺寸	CPU	内存	使用年限	价格 (美元)
x_0	x_1	x_2	x_3	x_4	y
1	4.1	1.1	24	3.5	570.5
1	5.5	1.2	2	1	918.9
1	6.2	1.2	26	2	980
.	.	.	.	.	.


$$\mathbf{w} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}$$

特征与广义线性回归



h_w 像素×像素 w_0 w_1 宽度 w_2 高度 x 显示区


域 宽度 高度 h_w 像素×像素 w_0 w_1 x



$$h_w = w_0 + w_1 x_1$$


$$w_0 \quad w_1 \text{psize}$$

● x_1 尺寸



h_w 像素宽度 $w_0 + w_1 x_1 + w_2 x_2$
 w_0 w_1 x_1 w_2 x_2
 w w psizeq w psizeq^2
 0 1 2


x_1 尺寸
 x_2 psizeq^2



$$h_w(\mathbf{x}) = w_0 + w_1x_1 + w_2x_2 + w_3x_3$$

$$= w_0 + w_1 \text{size} + w_2 \text{size}^2 + w_3 \text{size}^3$$

x_1 size
 x_2 size^2
 x_3 size^3



$$h_w \text{ pxq } w_w \text{ psizeq } w \text{ psizeq}^2_2$$

h_w 像素宽度 $w_0 w_1$ 尺寸 ?




多项式系列

$$\mathbf{F} \begin{pmatrix} x \\ x^2 \\ x^3 \\ x \\ \vdots \\ x^n \end{pmatrix}$$

一般函数


$$\Phi(x) = \begin{pmatrix} \varphi_1(x) \\ \varphi_2(x) \\ \vdots \\ \varphi_n(x) \end{pmatrix}$$

正则化




w_0 w_1x

欠拟合 高偏差



w_0 w_1x w_2x^2

恰到好处



w_0 w_1x w_2x^2 w_3x^3 w_4x^4

过拟合 高方差

$$J_{p,q} = \frac{1}{2m} \sum_{i=1}^m \left(\mathbf{h}_i^T \mathbf{D}_x^{-1} \mathbf{a} - \mathbf{v}^T \boldsymbol{\pi}_q \right)^2$$



$$J_{\text{pwq}} = \frac{1}{2m} \sum_{i=1}^m \left\| \mathbf{D}_i \mathbf{x}^{(i)} - \mathbf{y}^{(i)} \right\|_2^2 + \lambda \sum_{j=1}^n \left\| \mathbf{w}_j \right\|_2^2$$



重复 {

$$w_0 := w_0 - \alpha \frac{1}{m} \sum_{i=1}^m h_{w_0}^{(i)}(x^{(i)} - y^{(i)})$$

$$w_j := w_j - \alpha \frac{1}{m} \sum_{i=1}^m h_{w_j}^{(i)}(x^{(i)} - y^{(i)}) + \frac{\lambda}{m} w_j, \quad j = 1, 2, 3, \dots, n$$

}



重复 {

$$w_0 := w_0 - \alpha \frac{1}{m} \sum_{i=1}^m h_{w_0}^{piq} x_{0piq} - y_{piq}$$

$$w_j := w_j - \alpha \frac{1}{m} \sum_{i=1}^m h_{w_j}^{piq} x_j^{piq} - y_{piq} \quad , \quad j = 1, 2, 3, \dots, n$$

}

$$w_j := w_j - \alpha \frac{\lambda}{m} q + \frac{1}{m} \sum_{i=1}^m h_{w_j}^{piq} x_j^{piq} - y_{piq}$$



$$\begin{bmatrix} \mathbf{w} & \mathbf{X}^T \mathbf{X} & \lambda \end{bmatrix} \begin{bmatrix} 0 & 1 & 1 & \dots & 1 \\ 1 & & & & \\ & 1 & & & \\ & & \ddots & & \\ & & & 1 & \end{bmatrix} \begin{bmatrix} \mathbf{X}^T \mathbf{y} \\ \\ \\ \\ \end{bmatrix}$$

贝叶斯线性回归



- 线性回归的误差函数可视为假设高斯噪声模型下的最大似然解。

- 假设目标变量 t 由确定性函数 $y = \mathbf{x} + \mathbf{w}$ 决定
并施加加性高斯噪声，使得

$$t = \mathbf{y}^T \mathbf{x} + \mathbf{w}^T \mathbf{q} + \varepsilon$$

其中 ε 是均值为零的高斯随机变量，其精度（方差的倒数）为 β 。

- 因此可写为

$$p(\mathbf{t} | \mathbf{x}, \mathbf{w}, \beta) = \prod_{q=1}^Q N(t_q | \mathbf{y}^T \mathbf{x} + \mathbf{w}^T \mathbf{q}, \beta^{-1})$$



- 现在考虑一组输入数据 $\mathbf{X} = \mathbf{x}_1, \dots, \mathbf{x}_N$ 及其对应的目标值 $t_1, \dots, t_N$ 。
- 我们将目标变量 t_n 聚合为列向量 $\mathbf{t}$ 。
- 我们得到似然函数的下列表达式

$$p(\mathbf{t} | \mathbf{X}, \mathbf{w}, \beta) = \prod_{n=1}^N p(t_n | \mathbf{x}_n, \mathbf{w}, \beta)$$



- 对似然函数取对数,

$$\ln p(\mathbf{p}|\mathbf{w}, \beta, \mathbf{q}) = \ln \prod_{n=1}^N p(y_n | \mathbf{x}_n, \mathbf{w}, \mathbf{q}, \beta) = \sum_{n=1}^N \ln p(y_n | \mathbf{x}_n, \mathbf{w}, \mathbf{q}, \beta)$$

$$= -\frac{1}{2} \sum_{n=1}^N \ln \beta - \frac{1}{2} \sum_{n=1}^N \ln p(y_n | \mathbf{x}_n, \mathbf{w}, \mathbf{q}, \beta)$$

- 其中均方误差函数定义为

$$E_D(\mathbf{w}, \mathbf{q}) = \frac{1}{2} \sum_{n=1}^N t_n (y_n - \mathbf{x}_n^T \mathbf{w} - \mathbf{q}^T \boldsymbol{\phi}(\mathbf{x}_n))^2$$



- 采用平方损失函数时，最优预测由条件期望 $h_{p|x}$ 给出，

$$h_{p|x} = E(t|x)$$

- 期望平方损失可表示为以下形式：

$$E(L_S) = \int (y - h_{p|x})^2 p(x) dx = \int (h_{t|x} - h_{p|x})^2 p(x, t) dx dt.$$

- 第二项与 y 无关，源于数据本身的内在噪声，代表预期损失的最小可达值。



- 第一项取决于我们对函数 $y_{\mathbf{p}|\mathbf{x};\mathbf{q}}$ 的选择。
 - 实际应用中，数据集 D 仅包含有限个数据点 N 。
- 考虑第一项的被积函数，对于特定数据集 D ，其形式为：

呈现如下形式： $y_{\mathbf{p}|\mathbf{x};\mathbf{q}} D_{\mathbf{q}} h_{\mathbf{p}|\mathbf{x};\mathbf{q}}^2$ 。
- 若将量 $E_D y_{\mathbf{p}|\mathbf{x};\mathbf{q}} D_{\mathbf{q}} s$ 相加再相减，然后展开：

$$\begin{aligned}
 & y_{\mathbf{p}|\mathbf{x};\mathbf{q}} D_{\mathbf{q}} E_D y_{\mathbf{p}|\mathbf{x};\mathbf{q}} D_{\mathbf{q}} s E_D y_{\mathbf{p}|\mathbf{x};\mathbf{q}} D_{\mathbf{q}} s h_{\mathbf{p}|\mathbf{x};\mathbf{q}}^2 \\
 & y_{\mathbf{p}|\mathbf{x};\mathbf{q}} D_{\mathbf{q}} E_D y_{\mathbf{p}|\mathbf{x};\mathbf{q}} D_{\mathbf{q}} s^2 E_D y_{\mathbf{p}|\mathbf{x};\mathbf{q}} D_{\mathbf{q}} s h_{\mathbf{p}|\mathbf{x};\mathbf{q}}^2 \\
 & 2 y_{\mathbf{p}|\mathbf{x};\mathbf{q}} D_{\mathbf{q}} E_D y_{\mathbf{p}|\mathbf{x};\mathbf{q}} D_{\mathbf{q}} s E_D y_{\mathbf{p}|\mathbf{x};\mathbf{q}} D_{\mathbf{q}} s h_{\mathbf{p}|\mathbf{x};\mathbf{q}}^2。
 \end{aligned}$$



- 现在我们对这个表达式取关于 D 的期望值，并注意到最后一项将消失，得到

$$E_D \left[\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \right] = E_D \left[\frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2 \right] + E_D \left[\frac{1}{n} \sum_{i=1}^n (\bar{y} - \hat{y}_i)^2 \right] + E_D \left[\frac{2}{n} \sum_{i=1}^n (y_i - \bar{y})(\bar{y} - \hat{y}_i) \right]$$


bias^2
variance

- 预期损失 pbiasq^2 噪声方差

pbiasq² E_D rypx, Dqs hpxq 2 ppxqdx

方差 $E_D y_{px}; DqE_D r_{ypx}; Dqs^2_{ppxqdx}$

噪声 $\text{rhpxqts}^2_{\text{ppx, tqdxdt}}$



我们的目标是使预期损失最小化，该损失已被分解为偏置项（平方）、方差项和常数噪声项之和。



- 我们已探讨过线性回归模型参数的最大似然估计方法。
- 有效模型复杂度由基函数数量决定。
- 正则化系数控制着有效模型复杂度。
- 如何为特定问题确定合适的模型复杂度？
 - 为何不能通过最大化似然函数来决定？



- 我们通过引入模型参数 w 的先验概率分布，开始贝叶斯处理线性回归问题。
- 请注意， $p(\mathbf{p}|\mathbf{w}, \mathbf{q})$ 是 w 的二次函数的指数。
- 因此对应的共轭先验由高斯分布给出：

$$p(\mathbf{w}|\mathbf{q}) \propto \exp\left(-\frac{1}{2}\mathbf{w}^T \mathbf{S}_0 \mathbf{w} + \mathbf{m}_0^T \mathbf{w}\right)$$



- 现在计算后验分布，其与似然函数与先验的乘积成正比。
- 由于选择了共轭高斯先验分布，后验分布也将是高斯分布。
- 后验分布形式为

$$p(\mathbf{w}|\mathbf{t}, \mathbf{q}) \propto p(\mathbf{w}|\mathbf{m}_N, \mathbf{S}_N) p(\mathbf{q})$$

其中

$$\mathbf{m}_N = \mathbf{S}_N^{-1} \mathbf{m} + \beta \Phi^T \mathbf{t}, \quad \mathbf{S}_N^{-1} = \mathbf{S}^{-1} + \beta \Phi^T \Phi.$$



- 让我们计算后验分布，它与似然函数与先验的乘积成正比。
- 由于选择了共轭高斯先验分布，后验分布也将是高斯分布。
- 后验分布形式为

$$p(\mathbf{w}|\mathbf{t}, \mathbf{q}) \propto N(\mathbf{w}|\mathbf{m}_N, \mathbf{S}_N) q$$

其中

$$\mathbf{m}_N = \mathbf{S}_N \mathbf{S}^{-1} \mathbf{m} + \beta \Phi^T \mathbf{t}, \quad \mathbf{S}_N^{-1} = \mathbf{S}^{-1} + \beta \Phi^T \Phi.$$

- 最大后验权重向量可简单表示为 $\mathbf{w}_{\text{MAP}} = \mathbf{m}_N$ 。



- 为简化起见，考虑特定形式的高斯先验分布

$$p(\mathbf{w}|\alpha, \mathbf{q}) = N(\mathbf{w}|\mathbf{0}, \alpha^{-1} \mathbf{I})$$

- 对应于 $\mathbf{w}$ 的后验分布为

$$\mathbf{m}_N = \frac{\beta \mathbf{S}_N \Phi^T \mathbf{t}}{\mathbf{S}_N^{-1} + \alpha \mathbf{I}}, \quad \mathbf{S}_N^{-1} = \beta \Phi^T \Phi.$$

- 考虑一个无限宽的先验分布 $S_0 = \alpha^{-1} \mathbf{I}$ ，其中 $\alpha \rightarrow 0$ ，其均值 $\mathbf{m}_N$ 将简化为最大似然值 $\mathbf{w}_{ML}$ 。




- 后验分布的对数等于对数似然函数与先验分布对数的和

$$\ln p(\mathbf{w}|\mathbf{t}, \mathbf{q}) = \frac{1}{2} \sum_{n=1}^N \left(t_n - \mathbf{w}^\top \boldsymbol{\phi}(\mathbf{x}_n; \mathbf{q}) \right)^2 - \frac{\alpha}{2} \mathbf{w}^\top \mathbf{w} + \text{常数}$$


- 最大化该后验分布等价于最小化正则化平方和误差函数，其中 $\lambda = \frac{\alpha}{N}$ 。



先验




预测






后验




预测






后验




预测






后验



预测





- 实际上，我们通常并不**关注** w 本身的值
- 而是关注对**新** x 值的 t 值进行预测。
- 这要求我们评估由以下参数定义的预测分布：

$$p(t|\alpha, \beta q) \quad p(t|w, \beta q) p(w|\alpha, \beta q)$$

该分布涉及两个高斯分布的卷积。



- 该预测分布具有如下形式：

$$p(\mathbf{t}|\mathbf{x}, \mathbf{t}, \alpha, \beta) = N(\mathbf{t}|\mathbf{m}, \sigma^2)$$


$$\mathbf{m} = \frac{1}{N} \sum_{n=1}^N \Phi(\mathbf{x}_n) \mathbf{y}_n$$

$$\sigma^2 = \frac{1}{N} \sum_{n=1}^N \Phi(\mathbf{x}_n) \Phi(\mathbf{x}_n)^T + \frac{1}{N} \sum_{n=1}^N \Phi(\mathbf{x}_n) \Phi(\mathbf{x}_n)^T$$

- 其中预测分布的方差由下式给出：

$$\sigma^2 = \frac{1}{N} \sum_{n=1}^N \Phi(\mathbf{x}_n) \Phi(\mathbf{x}_n)^T + \frac{1}{N} \sum_{n=1}^N \Phi(\mathbf{x}_n) \Phi(\mathbf{x}_n)^T$$

- 第一项表示数据中的噪声
- 第二项反映参数 $\mathbf{w}$ 相关的不确定性。
- 由于噪声过程与 $\mathbf{w}$ 的分布是独立的高斯分布，其方差具有加性关系。




- 预测分布示例

对于包含9个高斯项的模型
基函数

- 包含大小为N的数据集
在图中以蓝色圆圈标示。

1、2、4 和 25 的数据集



- 由以下模型构成的预测分布示例

9个高斯基函数


- 数据集大小为 N

1, 2, 4, 以及

25的数据集在图中分别用

蓝色圆圈标出。

- 随着额外数据点的
后验分布变得更窄。



由以下模型构成的预测分布示例：


9个高斯基函数

大小为 N 的数据集

1, 2, 4, 以及
25的

蓝色圆圈标出。

随着额外数据点的
后验分布变得更窄。



预测分布示例

对于由9个高斯分布组成的模型
基函数

- 包含大小为 N 的数据集 1、2、4 和 25 的数据集
在图中以蓝色圆圈表示。
- 当 N 趋近于 ∞ 时，第二项
趋近于零，而预测分布的方差完全源于由参数 β 控制的加性
噪声。