

线性模型：分类

机器学习（双语）

齐飞 (Fei **Qi**) xfred.qi@ieee.org

李阳 (Yang **Li**)

2024年3月

人工智能学院

西安电子科技大学





分类的线性模型分类的最小二乘法感知机

逻辑回归

分类的线性模型



分类目标

将输入向量 $\mathbf{x}$ 分配到 K 个离散类别 C_k 之一，其中

$k = 1, \dots, K$.

判别函数

判别函数是一种函数，它接收输入**向量** $\mathbf{x}$ ，并将其分配到

K 个类别之一，记为 C_k 。



线性判别函数的表示形式通过对输入向量取线性函数获得，即：

$$y = \mathbf{w}^T \mathbf{x} + w_0$$

- $\mathbf{w}$ 称为权重向量， w_0 为偏置项



线性判别函数的表示形式通过对输入向量取线性函数获得，使得

$$y(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0$$

- $\mathbf{w}$ 称为权重向量， w_0 为偏置量判别函数
- 若输入向量 $\mathbf{x}$ 满足 $y(\mathbf{x}) \geq 0$ ，则归类到类 C_1
- 否则归入类 C_2 。
- 因此对应的决策边界由下列关系式定义：
 $y(\mathbf{x}) = 0$,
- 该关系对应于输入空间中一个 $(D-1)$ 维超平面。
 D 维输入空间中 $(D-1)$ 维超平面。




- 考虑两个点 $\mathbf{x}_A$ 和 $\mathbf{x}_B$ ，它们都位于决策面上。
- 由于 $y\mathbf{p}\mathbf{x}_A - q = y\mathbf{p}\mathbf{x}_B - q = 0$ ，我们有 $\mathbf{w}^T \mathbf{p}\mathbf{x}_A - \mathbf{x}_B - q = 0$
- 因此向量 $\mathbf{w}$ 与决策面内所有向量正交。
- 因此 $\mathbf{w}$ 决定了决策面的方向。



- 若 $\mathbf{x}$ 是决策面上的点, 则 y_{px_q}
 $0,$
- 从原点到决策表面的法向距离由下式给出
:

$$\frac{\mathbf{w}^T \mathbf{x}}{\|\mathbf{x}\|} = \frac{w_0}{\|\mathbf{w}\|}$$

- 偏置参数 w_0 决定决策面的位置。





与决策面相关的几何

- $y(\mathbf{x})$ 的值提供了一个带符号的度量，表示点 $\mathbf{x}$ 到决策面的垂直距离 r 。
- 考虑任意点 $\mathbf{x}$ ，令 $\mathbf{x}_K$ 为其在决策表面上的正交投影

表面


$$\mathbf{x} - \mathbf{x}_K = r \frac{\mathbf{w}}{\|\mathbf{w}\|}$$

- 将此结果两边乘以 $\mathbf{w}^T$

并加上 w_0 ，利用

$y(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0$ 以及

$y(\mathbf{x}_K) = \mathbf{w}^T \mathbf{x}_K + w_0 = 0$ ，我们得到






- 现在考虑线性判别式在 $K > 2$ 类中的扩展。
- 我们可能会试图通过组合多个二分类判别函数来构建 K 类判别函数。
- 然而，这会导致一些严重困难。




- 考虑使用 $k-1$ 分类器
- 每个分类器都解决一个二分类问题，即
从点集
属于特定类别 C_k 的点与不
该类别的数据点
- 在涉及三个类别的示例中，这种方法导致输入空间中出现分类模糊的区域。





- 替代方案是引入K近邻分类器
- 每个可能的类对各定义一个判别函数
- 每个点最终根据判别函数的多数投票结果进行分类。
- 这也遇到了模糊区域





- 单个K类判别式包含K个线性函数，形式为

$$y_k(\mathbf{x}) = \mathbf{w}_k^T \mathbf{x} + w_{k0}$$

- 若满足条件，则将点 $\mathbf{x}$ 分配至类 C_k 满足条件时

$$y_k(\mathbf{x}) > y_j(\mathbf{x}) \quad \forall j \neq k$$

- 类 C_k 与 C_j 之间的决策边界由 $y_k(\mathbf{x}) = y_j(\mathbf{x})$ 给出

- 对应于由 $pD - 1$ 维超平面定义的

$$(\mathbf{w}_k - \mathbf{w}_j)^T \mathbf{x} + (w_{k0} - w_{j0}) = 0$$

- 这与二分类情况下的决策边界具有相同形式。




决策区域是单连通且凸的

- 考虑两个点 x_A 和 x_B ，它们都位于决策区域 $\mathcal{Y}_k$ 内。
- 任何位于连接点 $x(A)$ 与 $x(B)$ 的直线上的点 $\hat{x}$ 与 x_B 连线的任意点 $\hat{x}$ 均可表示为

$$\hat{x} = \lambda x_A + (1 - \lambda) x_B$$

其中 $0 \leq \lambda \leq 1$ 。





- 由判别函数的线性性可得：


$$y_k p(\hat{x}) = \lambda_{y(k)} p(x_{(A)}) + (1 - \lambda) y_k p(x_B)$$

- 由于 x_A 和 x_B 均位于 Y_k 内部，故有 $y_k p(x_A) = y_j p(x_A)$

且

$$y_k p(x_B) = y_j p(x_B), \text{ 对所有 } j \neq k.$$

- 因此 $y_k p(\hat{x}) = y_j p(\hat{x})$ ，故 $\hat{x}$ 也位于 Y_k 内部。



分类问题的最小二乘法



- 每个类 C_k 均由其自身的线性模型描述, 使得

$$y_k = \mathbf{p}^T \mathbf{x} \mathbf{q} \quad \mathbf{w}_k^{(T)} = \mathbf{x} \quad \mathbf{w}_{k0}$$

其中 $k = 1, \dots, K$ 。

- 我们可采用向量记法将这些表达式便捷地归类为:

$$y \mathbf{p}^T \mathbf{x} \mathbf{q} = \tilde{\mathbf{w}}^T \tilde{\mathbf{x}}$$

其中 $\tilde{\mathbf{w}}$ 是矩阵, 其第 k 列由 $pD + 1$ 维向量构成

$\tilde{\mathbf{w}}_k = p \mathbf{w}_{k0}, \mathbf{w}_k^T \mathbf{q}^T$ 且 $\tilde{\mathbf{x}}$ 是对应的扩展输入向量

$p+1, \mathbf{x}^T \mathbf{q}^T$ 带虚拟输入 $x_0 = 1$.



确定参数矩阵

- 我们通过最小化均方误差函数来确定参数矩阵 $\tilde{w}$ 。
- 考虑训练数据集 $\mathbf{t}_n, \mathbf{t}_n^u$ 其中 $n = 1, \dots, N$, 并定义矩阵 $\mathbf{T}$, 其第 n 行为向量 $\mathbf{t}^T$, 同时定义矩阵 $\tilde{\mathbf{x}}$, 其第 n 行为 $\tilde{\mathbf{x}}^T_{q_n}$
- 平方误差函数可表示为

$$E_D(\tilde{\mathbf{w}}) = \frac{1}{2} \text{Tr}(\tilde{\mathbf{x}} \tilde{\mathbf{w}} \tilde{\mathbf{w}}^T \mathbf{T}^T - \mathbf{T} \tilde{\mathbf{x}} \tilde{\mathbf{w}} \tilde{\mathbf{w}}^T \mathbf{T}^T) = \frac{1}{2} \text{Tr}(\tilde{\mathbf{x}} \tilde{\mathbf{w}} \tilde{\mathbf{w}}^T \mathbf{T}^T - \mathbf{T} \tilde{\mathbf{x}} \tilde{\mathbf{w}} \tilde{\mathbf{w}}^T \mathbf{T}^T).$$



- 将 $\tilde{\mathbf{w}}$ 的导数设为零，并重新排列，我们得到
得到 $\tilde{\mathbf{w}}$ 的解为

$$\tilde{\mathbf{w}} = \mathbf{p} \tilde{\mathbf{x}}^T \tilde{\mathbf{x}}^q \mathbf{1} \tilde{\mathbf{x}}^T \mathbf{T} \tilde{\mathbf{x}}^{\dagger T}$$

其中 $\tilde{\mathbf{x}}^{\dagger}$ 是矩阵 $\tilde{\mathbf{x}}$ 的伪逆矩阵。

- 由此得到判别函数的形式为

$$y(\mathbf{x}) = \tilde{\mathbf{w}}^T \tilde{\mathbf{x}} = \mathbf{T}^T \tilde{\mathbf{x}}^{\dagger T} \tilde{\mathbf{x}}.$$



- 具有多个目标变量的最小二乘解的一个有趣特性是：若训练集中每个目标向量都满足某个线性约束

$$\mathbf{a}^T \mathbf{t}_n = b = 0$$

对于某些常数 $\mathbf{a}$ 和 b ，那么模型对任意 $\mathbf{x}$ 值的预测都将满足相同约束，从而

$$\mathbf{a}^T \mathbf{y}(\mathbf{x}) = b = 0.$$


- 因此，若采用K类别的1-of-K编码方案，模型生成的预测将具有以下特性：对于任意 $\mathbf{x}$ 值， $\mathbf{y}(\mathbf{x})$ 的元素之和均等于1。





$$\mathbf{a}^T \mathbf{y} p x q = b = 0$$

- 然而，仅凭这个求和约束还不足以使模型输出被解释为概率，因为它们不受限于区间 $p \in [0, 1]$ 之内。

最小二乘解对异常值缺乏鲁棒



图表显示了两个班级的数据，分别用红色叉号和蓝色圆圈标注。



感知器



- 它在模式识别史上占据重要地位
- 左图展示了如何通过简单的摄像系统获取输入。
- 印刷字符在强光照射下呈现。
- 图像聚焦于 20×20 的硫化镉光电二极管阵列（ ），形成原始的400像素图像。



- 感知器还配备了中间照片所示的接线板，可尝试不同输入特征的配置组合。



- 二元分类模型
- 输入**向量** x 首先通过固定非线性变换生成特征向量 $\phi(x)$
- 特征向量随后被用于构建广义线性模型：

$$y(x) = f(w^T \phi(x)) \quad (\text{感知器})$$

- 其中非线性激活函数 $f(a)$ 由阶跃函数给出：

$$f(a) = \begin{cases} 1, & a \geq 0 \\ 0, & a < 0 \end{cases}$$

- 向量 $\phi(x)$ 通常包含一个偏置分量 $\phi_0(x) = 1$ 。



- 在先前关于二元分类问题的讨论中，我们关注的是目标编码方案 $t \in \{0, 1\}$ ，该方案适用于概率模型的情境。
- 然而对于感知器而言，采用目标值 $t = 1$ 对应类别 C_1 ， $t = -1$ 对应类别 C_2 ，这与激活函数的选择相匹配。



- 为确定参数 w
- 误差函数的自然选择是分类错误模式的总数。
- 这导致 w 的分段常数函数，**在 w 的任何变化导致决策边界穿过数据点时都会出现不连续性。**
- 基于误差函数梯度调整 w 的方法此时无法适用，因为梯度在几乎所有位置都为零。



- 为求解权重向量 $\mathbf{w}$, 使得
 - 类 C_1 中的模式 $\mathbf{x}_n$ 满足 $\mathbf{w}^T \boldsymbol{\phi}(\mathbf{x}_n) \geq 0$,
 - 而类 C_2 中的模式 $\mathbf{x}_n$ 满足: $\mathbf{w}^T \boldsymbol{\phi}(\mathbf{x}_n) \leq 0$ 。
- 采用 $t \in \{-1, 1\}$ 目标编码方案, 可得所有模式均满足

$$\mathbf{w}^T \boldsymbol{\phi}(\mathbf{x}_n) - t_n \geq 0$$

- 感知器判别准则将零误差与任何被正确分类的模式关联, 而对于被误分类的模式 $\mathbf{x}_{(n)}$, 它试图最小化量 $-\mathbf{w}^T \boldsymbol{\phi}(\mathbf{x}_{(n)})$



因此感知器判别准则可表示为

$$E_p(w) = \sum_{n \in M} \max(0, w^T \phi(x_n) - t_n)$$

其中M表示所有误分类模式的集合。

- 特定误分类模式对误差的贡献，在该模式被误分类的w空间区域内是w的线性函数
- 而在正确分类的区域内，该贡献为零。
- 因此总误差函数呈分段线性形式。



- 现在我们将随机梯度下降算法应用于该误差函数。
- 权重**向量** $\mathbf{w}$ 的变化量由下列公式给出：


$$\mathbf{w}^{p(\tau+1)q} = \mathbf{w}^{p(\tau)q} - \eta \nabla E_p(\mathbf{w}^q) = \mathbf{w}^{p\tau q} - \eta \varphi_n t_n$$

其中 η 是学习率， τ 表示算法的迭代步数。


- 由于感知器函数 $y_{\mathbf{p}\mathbf{x}}, w_{\mathbf{q}}$ 在 $\mathbf{w}$ 乘以常数后不变，为保持一般性，我们设定 $\eta = 1$ 。
- 需注意，随着训练过程中权重向量的演变，被误分类的模式集合将随之变化。





- 我们依次遍历训练样本，对每个样本 x_n 评估感知器函数。
- 若模式被正确分类，则权重向量保持不变
- 若分类错误，则
 - 对于 C_1 类, 我们将向量 $\phi \mathbf{p} \mathbf{x}_n \mathbf{q}$ 添加到当前权重向量 $\mathbf{w}$ 的估计值上
 - 而对于类别 C_2 , 则从 $\mathbf{w}$ 中减去向量 $\phi \mathbf{p} \mathbf{x}_n \mathbf{q}$ 。



- 图中以黑色箭头显示初始参数向量 w 及其对应的决策边界（黑线），箭头指向被归类为红色类别的决策区域。
- 绿色圆圈标记的数据点属于误分类。



- 因此，将误分类样本的特征向量添加到当前权重向量中，从而得到图中所示的新决策边界。



● 左图：待考虑的下一个误分类点（绿色圆圈）



- 右：所有数据点均被正确分类的决策边界。



- 若考察感知器学习算法中单次更新的影响，可发现误分类模式对误差的贡献将减小，我们得到：

$$w^{(p)}(\tau) \mathbf{q}^T \boldsymbol{\varphi}_{nn}(\mathbf{t}) - w^{(p+1)}(\tau) \mathbf{q}^T \boldsymbol{\varphi}_{nn}(\mathbf{t}) = p \boldsymbol{\varphi}_{nn}(\mathbf{t}) \mathbf{q}^T \boldsymbol{\varphi}_{nn}(\mathbf{t})$$

- 这并不意味着其他误分类模式对误差函数的贡献会减少。
- 因此，感知器学习规则无法保证在每个阶段都能降低总误差函数。



- 然而，感知器收敛定理指出：若存在精确解（换言之，若训练数据集可线性分离），则感知器学习算法必能在有限步数内找到精确解。
- 该定理的证明可参见Rosenblatt（1962）、Block（1962）、Nilsson（1965）、Minsky和Papert（1969）、Hertz等人（1991）以及Bishop（1995a）等文献中。



- 但需注意，达到收敛所需的迭代次数仍可能相当可观。实践中，在收敛达成前，我们无法区分问题本质上不可分离，还是单纯收敛速度缓慢。
- 即使数据集具有线性可分性，仍可能存在多个解，具体解的选择取决于参数初始化方式及数据点的呈现顺序。
- 此外，对于不可线性分离的数据集，感知器学习算法永远无法收敛。

逻辑回归




- 电子邮件：垃圾邮件/非垃圾邮件
- 在线交易：欺诈（是/否）
- 肿瘤：良性/恶性

目标变量为离散型

$t \in \{0, 1\}$

- “0”：负类（例如良性肿瘤）
- “1”：阳性类（例如恶性肿瘤）



- 将 $h_w pxq$ 的输出分类
- 的输出进行分类, 阈值设为0.5:

- 当 $h_w pxq \geq 0.5$ 时, 预测 $t = 1$
- 若 $h_w pxq < 0.5$, 则预测 $t = 0$

- 分类输出结果为

$t = 0$ 或 1

- 在回归中, 输出可能是 -1 或 1

逻辑回归

$$0 \leq h_w pxq \leq 1$$



逻辑回归模型期望

$$0 \leq h_{\mathbf{w}}(\mathbf{x}) \leq 1$$

因此我们用以下形式表示它

$$h_{\mathbf{w}}(\mathbf{x}) = g(\mathbf{w}^T \mathbf{x}).$$



逻辑回归模型期望

$$0 \leq h_{\mathbf{w}}(\mathbf{x}) \leq 1$$

因此我们用以下形式表示：

$$h_{\mathbf{w}}(\mathbf{x}) = g(\mathbf{w}^T \mathbf{x}).$$

Sigmoid/Logistic函数

$$g(z) = \frac{1}{1 + \exp(-z)}.$$



逻辑回归模型预期


$$h_{\mathbf{w}}(\mathbf{x}) \in [0, 1]$$

因此我们用以下形式表示它

$$h_{\mathbf{w}}(\mathbf{x}) = g(\mathbf{w}^T \mathbf{x}).$$

Sigmoid/Logistic函数

$$g(z) = \frac{1}{1 + \exp(-z)}$$





逻辑回归模型的概率性解

假设 $h_{\mathbf{w}} \mathbf{x}$ 估计输出为 t 的概率为 1
 根据给定输入 $\mathbf{x}_0$ 。

示例

若我们有

$\mathbf{x}$	x_0	1
	x_1	肿瘤大小
	$h_{\mathbf{w}} \mathbf{x}$	0.7

由此可知，该患者患恶性肿瘤的概率为70%。

肿瘤。



假设 $h_{\mathbf{w}}(\mathbf{x})$ 估计输出为 t 的概率, $t \in \{0, 1\}$
根据给定输入 $\mathbf{x}$ 。

示例

若我们有

$\mathbf{x}$	x_0	1
	x_1	肿瘤大小
$h_{\mathbf{w}}(\mathbf{x})$		0.7

概率性解释

$$h_{\mathbf{w}}(\mathbf{x}) = P(t=1 | \mathbf{x}; \mathbf{w})$$

在参数 $\mathbf{w}$ 下, 当输入为 $\mathbf{x}$ 时, 输出为 t 的概率为
 $h_{\mathbf{w}}(\mathbf{x})$ 。

由此可知, 患者患有恶性肿瘤的概率为70%。



假设 $h_w(x)$ 估计输出为 $t = 1$ 的概率
根据给定的输入 x 。

示例

若我们有

x	x_0	1
	x_1	肿瘤大小
	$h_w(x)$	0.7

由此可知，患者患恶性肿瘤的概率为70%

肿瘤。

概率性解释

$$h_w(x) = P(t = 1 | x; w)$$

在参数 w 下，当输入为 x 时，输出为 t 的概率为
1。

$$P(t = 0 | x; w) = P(t = 1 | x; w) = 1$$



逻辑回归模型的概率性解

假设 $h_w(x)$ 估计输出为 $t = 1$ 的概率
根据给定的输入 x 。

示例

若我们有

x	x_0	1
	x_1	肿瘤大小
	$h_w(x)$	0.7

由此可知，患者患恶性肿瘤的概率为70%

肿瘤。


概率性解释

$$h_w(x) = P(t = 1 | x; w)$$


在参数 w 下，当输入为 x 时，输出为 t 的概率为
1。

$$P(t = 0 | x; w) + P(t = 1 | x; w) = 1$$

$$P(t = 0 | x; w) = 1 - P(t = 1 | x; w)$$




$$h_{\mathbf{w}}(\mathbf{x}) = \frac{\mathbf{g}^T \mathbf{w} \mathbf{x}}{1 + \exp(\mathbf{g}^T \mathbf{w} \mathbf{x})}$$



$$h_{\mathbf{w}}(\mathbf{x}) = \frac{\mathbf{g}^T \mathbf{w}^T \mathbf{x}}{1 + \exp(-\mathbf{z})}$$

因此：

- 若 $h_{\mathbf{w}}(\mathbf{x}) \geq 0.5$ ，模型输出 $t = 1$
- $\mathbf{w}^T \mathbf{x} \geq 0$



$$h_{\mathbf{w}}(\mathbf{x}) = \frac{\mathbf{g}^T \mathbf{w}}{1 + \exp(-\mathbf{z})}$$

因此:

- 若 $h_{\mathbf{w}}(\mathbf{x}) \geq 0.5$, 模型输出 $t = 1$
 - $\mathbf{w}^T \mathbf{x} \geq 0.0$
- 若 $h_{\mathbf{w}}(\mathbf{x}) < 0.5$, 模型输出 $t = 0$
 - $\mathbf{w}^T \mathbf{x} < 0.0$



$$h_{\mathbf{w}}(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$$

$$\mathbf{w} = \begin{bmatrix} 3 \\ 1 \\ 1 \end{bmatrix}$$



$$h_{\mathbf{w}}(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0$$

$$\mathbf{w} = \begin{bmatrix} w_1 \\ w_2 \\ 1 \end{bmatrix}$$

那么输出为

$t = 1$ 的条件是

$$\mathbf{w}^T \mathbf{x} + w_0 \geq 0,$$

即,

$$x_1 + x_2 \geq 3$$



$$h_{\mathbf{w}}(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$$

$$\mathbf{w} = \begin{bmatrix} w_0 \\ w_1 \\ w_2 \end{bmatrix}$$


那么输出为

$t = 1$ 的条件是

$$w_0 + w_1 x_1 + w_2 x_2 \geq 0$$

即,

$$x_1 + x_2 \geq 3$$





$$h_{\mathbf{w}}(\mathbf{p}, \mathbf{q}) = g(\mathbf{w}^T \mathbf{x})$$

$$\mathbf{w} = [w_0, w_{11}, w_{22}, w_{31}, w_{42}]^T$$

$$\mathbf{x} = [1, x_1, x_2, x_1^2, x_1 x_2]^T$$



非线性（圆形）决策边界

$$h_{\mathbf{w}}(\mathbf{p}, \mathbf{q}) = g(\mathbf{w}^T \mathbf{x}) = w_0 + w_1 x_1 + w_2 x_2 + w_3 x_1^2 + w_4 x_2^2$$


$$\mathbf{w} = [1, 0, 0, 1, 1]^T$$

那么输出为

$t = 1$ 的条件是

$$1 - x_1^2 - x_2^2 \geq 0,$$

$$\text{即 } x_1^2 + x_2^2 \leq 1$$





非线性（圆形）决策边界

$$h_{\mathbf{w}}^T \mathbf{p} \mathbf{x} \mathbf{q} = g(\mathbf{w})_0 + \mathbf{w}_1 x_1 + \mathbf{w}_2 x_2 + \mathbf{w}_3 x_1^2 + \mathbf{w}_4 x_2^2$$


$$\mathbf{w} = \begin{bmatrix} 1 & 0 & 0 & 1 & 1 \end{bmatrix}^T$$

那么输出为

$t = 1$ 的条件是

$$\begin{aligned} &1 - x_1^2 - x_2^2 \geq 0, \\ \text{即, } &x_1^2 + x_2^2 \leq 1 \end{aligned}$$

$$h_{\mathbf{w}} = g(\mathbf{w})_0 + \mathbf{w}_1 x_1 + \mathbf{w}_2 x_2 + \mathbf{w}_3 x_1^2 + \mathbf{w}_4 x_1^2 x_2 + \mathbf{w}_5 x_1^2 x_2^2 + \mathbf{w}_6 x_1^3 x_2 + \dots \mathbf{q}$$





训练集包含 m 个样本,

$$\{ \mathbf{x}^{(1)}, t^{(1)}, \mathbf{x}^{(2)}, t^{(2)}, \dots, \mathbf{x}^{(m)}, t^{(m)} \}$$

其中

$$\mathbf{x} = \begin{bmatrix} x_0 \\ x_1 \\ \vdots \\ x_n \end{bmatrix} \in \mathbb{R}^{n+1}, \quad t \in \mathbb{R}$$

假设为

$$h_{\mathbf{w}}(\mathbf{x}) = \frac{1}{1 + \exp(-\mathbf{w}^T \mathbf{x})}$$

如何获取参数 $\mathbf{w}$?



$$J(w) = \frac{1}{2m} \sum_{i=1}^m \text{成本 } h_w(\mathbf{x}^{(i)}, t^{(i)})$$

- 线性回归

$$\begin{aligned} \text{成本 } h_w(\mathbf{x}^{(i)}, t^{(i)}) &= \frac{1}{2} \|\mathbf{w}^T \mathbf{x}^{(i)} - t^{(i)}\|^2 \\ &= \frac{1}{2} (\mathbf{w}^T \mathbf{x}^{(i)} - t^{(i)})^2 \end{aligned}$$

- 逻辑回归

$$\text{成本 } h_w(\mathbf{x}^{(i)}, t^{(i)}) = -\frac{1}{2} \ln \frac{1}{1 + \exp(-\mathbf{w}^T \mathbf{x}^{(i)})} - t^{(i)} \mathbf{w}^T \mathbf{x}^{(i)}$$




$$J(w) = \frac{1}{2m} \sum_{i=1}^m \text{成本 } h_w(\mathbf{x}^{(i)}) - y^{(i)}$$

- 线性回归

$$\text{成本 } h_w(\mathbf{x}^{(i)}) - y^{(i)} = \frac{1}{2} (\mathbf{w}^T \mathbf{x}^{(i)} - y^{(i)})^2$$

- 逻辑回归

$$\text{成本 } h_w(\mathbf{x}^{(i)}) - y^{(i)} = \frac{1}{2} \left(\frac{1}{1 + \exp(-\mathbf{w}^T \mathbf{x}^{(i)})} - y^{(i)} \right)^2$$






成本 $J(w)$ 与 $\log h(w, x)$ 的关系

当 $t = 1$ 时，成本函数为 0。

当 $h(w, x) = 0$ 时，成本函数趋近于 8。



当 $h(w, x) = 0$ 但 $t < 1$ 时，学习曲线该算法将受到此成本函数的严厉惩罚。





成本 x $\log h_{w,p,q,t}$ $\log h_{w,p,q}$ 1 h_w 若 $t = 1$ $t = 0$

- 当 $t = 1$ 且 $h_{w,p,q} = 1.0$ 时，成本函数为 0。
- 当 $h_{w,p,q} = 0$ 时，成本函数趋近于 ∞ 。
- 当 $h_{w,p,q} = 0$ 但 $t = 1$ 时，学习该算法将受到此成本函数的严厉惩罚。





$$J(p, w, q, t) = \frac{1}{m} \sum_{i=1}^m \text{成本}_{i1} = \frac{1}{m} \sum_{i=1}^m \left(\log \frac{h_w(p x_i, q, t)}{1 + h_w(p x_i, q, t)} \right)$$

当 $t = 1$ 时， $\log \frac{h_w(p x_i, q, 1)}{1 + h_w(p x_i, q, 1)}$ 可以简化为 $\log \frac{1}{2}$ ，因此成本函数可以简化为 $J(p, w, q) = \frac{1}{m} \sum_{i=1}^m \log \frac{1}{2}$ 。



$$J(p, w, q) = \sum_{i=1}^m \text{成本}_{i1} = \sum_{i=1}^m h_w(p^{piq}, q, t^{piq})$$

$$\text{成本}_{i1} = \begin{cases} \log h_w(p^{piq}, q) & \text{当 } t^{piq} = 1 \\ \log(1 + h_w(p^{piq}, q)) & \text{若 } t^{piq} = 0 \end{cases}$$

考虑到 $t = 1$ 或 $t = 0$ ，我们有

成本 $ph_w(p^{piq}, tq)$



$$J(p, w, q) = \sum_{i=1}^m \text{成本}_{i1}$$

$$\text{成本}_{i1} = h_w(p x_i, q, t_i)$$

$$h_w(p x_i, q, t_i) = \begin{cases} \log h_w(p x_i, q) & \text{当 } t_i = 1 \\ \log(1 + h_w(p x_i, q)) & \text{若 } t_i = 0 \end{cases}$$

考虑到 $t_i = 1$ 或 $t_i = 0$ ，我们有

$$\text{成本}_{i1} = p h_w(p x_i, q, t_i) = t_i \log h_w(p x_i, q)$$



$$J_{\text{pwq}} = \frac{1}{m} \sum_{i=1}^m \text{成本 } h_{\text{w}}^{\text{piq}}(\mathbf{x}_i, \mathbf{t}_i)$$

$$\text{成本}_p = \begin{cases} \log h_{\text{w}}(\mathbf{x}_q) & \text{当 } t = 1 \\ \log(1 - h_{\text{w}}(\mathbf{x}_q)) & \text{若 } t = 0 \end{cases}$$

$$h_{\text{w}}(\mathbf{x}_q)$$

考虑到 $t = 1$ 或 $t = 0$ ，我们有

$$\text{成本}_p(\mathbf{x}_q, t) = t \log h_{\text{w}}(\mathbf{x}_q) + (1-t) \log(1 - h_{\text{w}}(\mathbf{x}_q))$$



$$J(w) = \frac{1}{m} \sum_{i=1}^m \text{cost}(w; x^{(i)}, t^{(i)})$$

$$\text{cost}(w; x^{(i)}, t^{(i)}) = \frac{1}{2} (h_w(x^{(i)}) - t^{(i)})^2 + \lambda \|w\|^2$$

- 求解参数 w 使得

$$w = \arg \min_w J(w)$$

- 对于未见过的输入 x , 预测

$$h_w(x) = \frac{1}{1 + \exp(-w^T x)}$$



$$J_{pwq} = \frac{1}{m} \sum_{i=1}^m \left(\frac{1}{2} \| \mathbf{p} - \mathbf{W} \mathbf{q} \|^2 + \lambda \sum_{j=1}^n w_j^2 \right)$$

最小化 J_{pwq}

重复直至收敛 {

$$w_j : w_j \leftarrow w_j - \alpha \frac{\partial}{\partial w_j} J_{pwq}$$

}

请记住同时更新所有 w_j 。



$$J(p, w) = \frac{1}{m} \sum_{i=1}^m \left(\frac{1}{2} (y_i - \hat{y}_i)^2 \right)$$

$$= \frac{1}{2m} \sum_{i=1}^m (y_i - w_0 - w_1 x_i)^2$$

重复直至收敛 {

$$w_{(j)} := \frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i) x_i$$

}

该算法与线性回归相似。