

计算学习理论

计算学习理论

机器学习（双语）

齐飞 (Fei **Qi**) xfred.qi@ieee.org

李阳 (Yang **Li**)

2023年11月

人工智能学院
西安电子科技大学





计算学习理论

计算学习理论



- 支持向量机主要基于一种称为计算学习理论¹的理论框架进行动机分析，该理论有时也被称为统计学习理论。
- 该理论源于近似正确性（PAC）学习框架（Valiant 1984）。

¹ 部分内容摘自 https://www.cs.cmu.edu/~lwehbe/10701_S19/files/Lecture_13.pdf



近似正确性 (**AC**) 要求算法必须学习到一个近似于真实函数的函数。

- 实践中通过误差参数 ϵ 进行量化

可能性 (**P**) : 学习算法应以高概率 (由参数 δ 量化) 学习出近似正确的函数。

PAC模型对机器学习算法的发展及其工作原理的理解产生了重大影响, 尤其在监督学习领域。



- 哪些普遍规律约束着归纳学习?
- 希望理论能关联
 - 训练样本数量
 - 假设空间的复杂度
 - 目标函数的逼近精度
 - 训练样本呈现方式
 - 成功学习的概率
- 参见年度计算学习理论会议



学习目标概念所需训练样本的数量

1. 若学习者将实例作为查询提出给教师？
 - 学习者提出 x ，教师提供 $p(x)$
2. 若教师（已知 $p(x)$ ）生成训练样本？
 - 教师提出序列 $x^1, f(x^1), \dots, x^n, f(x^n)$
3. 若随机过程（如自然）生成实例，由教师标注？
 - 实例按概率分布 $p(x)$ 抽取



问题设定：

- 实例集 X
- 假设集 H $h : X \rightarrow \{0, 1\}$
- 可能的目标函数集 C $c : X \rightarrow \{0, 1\}$
- 从 $P \times X^q$ 中随机抽取的训练实例序列提供无噪声标签 $c(x_i)$

学习器输出假设 $h \in H$ ，满足

$$h = \arg \min_{h \in H} \text{error}_{\text{train}}(h)$$



取 $X = pX_1, \dots, X_n$ 使得 $X_i \in \{0, 1\}$, $Y_i \in \{0, 1\}$



取 $\mathbf{X} = (X_1, \dots, X_n)$ 使得 $X_i \in \{0, 1\}$, $Y_i \in \{0, 1\}$ 设 H 为决策

树集合： $H = \{h : \mathbf{X} \rightarrow Y \mid \mathbf{X} \text{ 有多少种可能的取值?}\}$



取 $\mathbf{X} = [x_1, \dots, x_n]^T$ 使得 $x_i \in \{0, 1\}$, $y_i \in \{0, 1\}$

设 H 为决策树集合: $H = \{h: \mathbf{X} \rightarrow Y\}$

$\mathbf{X}$ 有多少种可能的取值?

2^n

可能的树有多少种?



取决策树集 H : $H = \{h : X \rightarrow Y \mid \exists q \text{ 使得 } X_i \sim P_{t(0, 1u)}, Y_i \sim P_{t(0, 1u)}\}$

设 H 为决策树集合: $H = \{h : X \rightarrow Y\}$

X 有多少种可能的取值?

2^n

可能的树有多少种?

$|H| = 2^{2^n}$

找到正确树需要多少训练样本?



取 $X = \{x_1, \dots, x_n\}$, 使得 $x_i \in \{0, 1\}$, $y_i \in \{0, 1\}$

设 H 为决策树集合: $H = \{h: X \rightarrow Y\}$

X 有多少种可能的取值?

2^n

可能的树有多少种?

$|H| = 2^{2^n}$

找到正确树所需的训练样本数是多少?

2^n (没有免费的午餐)



取决策树集合 H : $H = \{h : X \rightarrow Y \mid \exists q \text{ 使得 } x(i) \in q \Rightarrow Y_i = q\}$

设 H 为决策树集合: $H = \{h : X \rightarrow Y\}$

X 有多少种可能的取值?

2^n

可能的树有多少种?

$|H| = 2^{2^n}$

找到正确树需要多少训练样本?

2^n (没有免费的午餐)

除非添加假设, 否则无法实现超出训练集的泛化



取决策树集 $H: H = \{h: X \rightarrow Y \mid \exists q \text{ 使得 } X_i \sim P_{t(0, 1u)}, Y_i \sim P_{t(0, 1u)}\}$

设 H 为决策树集合: $H = \{h: X \rightarrow Y\}$

X 有多少种可能的取值?

2^n

可能的树有多少种?

$|H| = 2^{2^n}$

找到正确树需要多少训练样本?

2^n (没有免费的午餐)

除非我们添加假设训练样本是根据分布 P 提供的, 否则无法实现训练之外的泛化



h 的真实误差是它将从 $P_{p \times q}$ 中随机抽取的样本误分类的概率

$$\text{真实错误率 } p_{hq} = \frac{1}{n} \sum_{i=1}^n \mathbb{I}(h(x_i) \neq y_i)$$



假设 h 相对于目标概念 c 的训练误差

- 在训练样本集 D 上, h 对 c 的预测值 $h(x)$ 与 c 的真实值 $c(x)$ 的匹配频率

$$\text{错误率}_{\text{训练}} = \frac{1}{|D|} \sum_{x \in D} \mathbb{I}(h(x) \neq c(x))$$



假设 h 相对于目标概念 c 的训练误差

- 在训练样本集 D 上, h 满足 的频率与 c 满足 的频率之比

$$\text{错误率}_{\text{训练}}(h) = \frac{\Pr_{x \in D} [h(x) \neq c(x)]}{\Pr_{x \in D} [c(x) \neq c(x)]} = \frac{1}{|D|} \sum_{x \in D} \mathbb{I}_{h(x) \neq c(x)}$$

假设 h 相对于 c 的真实误差

- 在从 D 中随机抽取的训练样本上, h 与 c 出现的频率

$$\text{错误率}_{\text{true}}(h) = \Pr_{x \sim P} [h(x) \neq c(x)]$$



考虑假设 h 及其

- 训练数据上的错误率: $\text{error}_{\text{train}}(h)$
- 所有数据上的真实错误率: $\text{error}_{\text{true}}(h)$

当满足以下条件时，我们说假设 h 过拟合了训练数据：

$$\text{error}_{\text{true}}(h) > \text{error}_{\text{train}}(h)$$

过拟合程度 =

$$\text{error}_{\text{true}}(h) - \text{error}_{\text{train}}(h)$$



考虑假设 h 及其

- 训练数据上的误差率: $\text{error}_{\text{train}}(h)$
- 所有数据的真实错误率: $\text{error}_{\text{true}}(h)$

当满足以下条件时，我们说模型对训练数据过拟合：

$$\text{error}_{\text{true}}(h) \gg \text{error}_{\text{train}}(h)$$

过拟合程度 =

$$\text{error}_{\text{true}}(h) - \text{error}_{\text{train}}(h)$$

能否用训练数据误差 $\text{error}_{\text{train}}(h)$ 限定真实数据误差 $\text{error}_{\text{true}}(h)$

错误训练 phq Pr $rhpq$ $cpxqs$ $\frac{1}{\top \bot \top}$ $\delta rhpq$ $cpxqq$
 xPD

$error_{true}$ phq Pr $rhpq$ $cpxqs$
 $x P pXq$

$$\text{错误}_{\text{训练}} = \frac{1}{|D|} \sum_{(x, y) \in D} \delta(h(x), y)$$

$$\text{error}_{\text{true}} = \mathbb{E}_{(x, y) \sim P} \delta(h(x), y)$$

若 D 是一组从 h 中抽取且独立于 h 的样本，则可采用标准统计置信区间法确定：在 95% 概率下，误差 error_D 位于区间：

$$\text{error}_D \pm 1.96 \sqrt{\frac{\text{error}_D(1 - \text{error}_D)}{n}}$$

但 D 是 h 的训练数据。



假设 h 与目标概念 c 的训练样本集 D 相容，当且仅当对于 D 中每个训练样本 p_x ，满足 $h(p_x) = c(p_x)$ 。

一致性条件: $h(p_x) = c(p_x), \quad \forall p_x \in D$



假设 h 与目标概念 c 的训练样本集 D 相容，当且仅当对于 D 中每个训练样本 px ，满足 $hpxq$ $cpxq$ 。

一致性条件: $hpxq \quad cpxq, \quad @px, cpxqq \ P \ D$

版本空间 版本空间 $V_{S_{H,D}}$ 针对假设空间 H 和训练样本集 D ，是 H 中与 D 中所有训练样本一致的假设子集。

$$V_{S_{(H,D)}} = \{h \in H \mid h \text{ consistent with } D\}$$



ϵ -穷尽 对于训练数据集 D ，若版本空间 $V_{S_{H,D}}$ 中每个假设 h 的真实误差均小于 ϵ ，则称该版本空间为 ϵ -穷尽。

$$\text{error}_{\text{true}}(h) < \epsilon \quad \forall h \in V_{S_{H,D}}$$



需要多少个例子才能将版本空间耗尽至 ϵ ?

定理 (**Haussler, 1988**) 若假设空间 H 为有限集, 且 D 是 m 个独立随机样本序列 (对应目标概念), 则对于任意 $0 < \epsilon < 1$, 以 H 和 D 为基准的版本空间未被 (针对) ϵ -穷尽的概率小于

$$|H|e^{-\epsilon m}$$



需要多少个样本才能使版本空间达到 ϵ -穷尽?

定理 (**Haussler, 1988**) 若假设空间 H 为有限集, 且 D 是 m 个独立随机实例序列 (对应目标概念 c), 则对于任意 $0 < \epsilon < 1$, 以 H 和 D 为基准的版本空间在 c 意义下未达到 ϵ -穷尽的概率小于

$$|H|e^{-\epsilon m}$$

有趣! 这界定了任何一致学习者输出错误率超过 ϵ 的假设 h 的概率。

- 任何(!)学习者若在训练后输出与所有训练样本一致的假设 (即 h 属于 $V_{S_{H,D}}$)

在 m 个训练样本后，其概率至多为 $|H|e^{-\epsilon m}$

$$\Pr_{D \sim P^m} \left[\exists h \in H \text{ s.t. } \text{error}_{\text{train}}(h) \leq \epsilon \text{ and } \text{error}_{\text{true}}(h) \geq \epsilon/2 \right] \leq \frac{|H|e^{-\epsilon m}}{1 - \epsilon/2}$$

假设我们希望该概率不超过 δ

1. 需要多少训练样本才足够?

$$m \geq \frac{1}{\epsilon} (\ln |H| + \ln \frac{1}{\delta})$$

2. 若训练集误差 $\text{error}_{(\text{train})} \leq \epsilon$ 则以至少概率 $1 - \delta$:

$$\text{错误率}_{\text{真实}} \leq \epsilon + \frac{1}{m} (\ln |H| + \ln \frac{1}{\delta})$$



示例: H 是最多 N 个布尔字母的合取式

考虑分类问题 $f: X \rightarrow Y$:

- 实例集: $X = \{x_1, x_2, x_3, x_4\}$ 其中每个 x_i 均为布尔值
- H 中每个假设规则形式如下:
 - IF $p_{x_1, x_2, x_3, x_4} \in \{0, 1, ?\}$, THEN $Y = 1$, ELSE $Y = 0$
 - 即规则约束任意子集

需要多少训练样本 m 才能确保, 当概率至少为 0.99 时, 任何使用 H 的一致性学习者输出的假设其真实误差不超过 0.05?



示例: H 是最多包含 N 个布尔字母的合取式

考虑分类问题 $f: X \rightarrow Y$:

- 实例集: $X = \{x_1, x_2, x_3, x_4\}$ 其中每个 x_i 为布尔值
- H 中每个假设规则形式如下:
 - 若 $(x_1, x_2, x_3, x_4) = (0, 1, 1, 0)$, 则 $Y = 1$, 否则 $Y = 0$
 - 即规则 C_i 的任意子集

需要多少个训练样本 m 才能确保, 使用 H 的任何一致学习者输出假设时, 真实误差不超过 0.05 的概率至少为 0.99?

$$m \geq \frac{1}{0.05} \frac{\ln |H|}{\ln 0.01} = \frac{1}{0.05} \frac{3^4}{\ln 3} \approx 100$$

$$m \geq \frac{1}{\epsilon} \ln |H| + \ln \frac{1}{\delta}$$



$$m \leq \frac{1}{\epsilon} \ln |H| + \ln \frac{1}{\delta} q$$

考虑分类问题 $f: X \rightarrow Y$:

- 实例集: $X = \{x_1, \dots, x_N\}$ 其中 ~~每个~~ x_i 为布尔值
- 学习到的假设是深度为2的决策树，仅使用两个变量



示例：深度为2的决策树

考虑分类问题 $f: X \rightarrow Y$:

$$m = \frac{1}{\epsilon} (\ln |H| + \ln \frac{1}{\delta})$$

- 实例: $X = \{x_1, \dots, x_N\}$, 其中每个 x_i 均为布尔值
- 学习到的假设是深度为2的决策树, 仅使用两个变量

$$\begin{aligned}
 & \text{2-树} \\
 & N \quad \frac{N!}{pN \cdot 2q!} \quad \frac{N \cdot pN}{2} \cdot 1q \\
 & \quad \quad \quad 2^4 \text{ 标记节点的途径} \\
 & |H| = 8N \cdot pN \cdot 1q
 \end{aligned}$$



示例：深度为2的决策树

考虑分类问题 $f: X \rightarrow Y$:

$$m \geq \frac{1}{\epsilon} (\ln |H| + \ln \frac{1}{\delta})$$

- 实例: $X = \{x_1, \dots, x_N\}$, 其中每个 x_i 均为布尔值
- 学习到的假设是深度为2的决策树, 仅使用两个变量

$$|H| = \sum_{p,q} \binom{N}{p} \binom{N-p}{q} = \sum_{p,q} \frac{N!}{p!q!(N-p-q)!}$$

2^4 标记节点的途径

$$|H| = \sum_{p,q} \binom{N}{p} \binom{N-p}{q} = \sum_{p,q} \frac{N!}{p!q!(N-p-q)!}$$

需要多少训练样本 m 才能确保, 当概率至少为0.99时, 任何输出深度为2的一致决策树的学习器, 其真实误差至多为0.05?

$$m \geq \frac{1}{0.05} (\ln \sum_{p,q} \binom{N}{p} \binom{N-p}{q} + \ln \frac{1}{0.01})$$



可能近似正确 (PAC) 学习

考虑在长度为 n 的实例集 X 上定义的可能目标概念类 C ，以及使用假设空间 H 的学习器 L 。

定义：若对于所有 $c \in C$ 、分布 D 上的 X 、满足 $0 \leq \epsilon \leq 1/2$ 的 ϵ ，以及满足 0

$\delta \leq 1/2$ 的 δ ，

学习器 L 将以概率至少 $1 - \delta$ 输出假设 $h \in H$ ，使得误差 $E(h) \leq \epsilon$ ，且所需时间为 $1/\epsilon, 1/\delta, n$ 和 $|C|$ 的多项式级。

可能近似正确 (**PAC**) 学习

考虑一个可能的目标概念类 C ，该类定义在长度为 n 的实例集 X 上，以及一个使用假设空间 H 的学习器 L 。

定义：若对于所有 $c \in C$ ， X 上的分布 D ，满足 $0 \leq \epsilon \leq 1/2$ ，且 δ 满足 $0 \leq \delta \leq 1/2$ ，则称 C 可由 L 使用 H 进行 **PAC** 学习。

学习者 L 将以至少概率 $1 - \delta$ 输出假设 $h \in H$ ，使得误差 $d_D(h, c) \leq \epsilon$ ，其时间复杂度为 $1/\epsilon, 1/\delta, n$ 和 $|H|$ 的多项式级。

充分条件：当学习者 L 仅需多项式数量的训练样本，且每例处理量为多项式时成立。



迄今为止，假设 cPH

无先验学习设置：不假设 cPH

- 那么我们追求什么？
 - 在训练数据上误差最少的假设 h
- 此情形下的样本复杂度是什么？

$$m \frac{1}{2\epsilon^2} \ln |H| \quad \ln p1\{\delta q$$

此处 ϵ 是输出假设（即训练误差最低的假设）的训练误差与真实误差之间的差值



- 在真实概率 $P_{\text{heads}} = \theta$ 下，给定 m 次独立抛硬币，可对最大似然估计 $\hat{\theta}$ 的误差进行界定

$$P(|\hat{\theta} - \theta| \geq \epsilon) \leq e^{-2m\epsilon^2}$$

- 与不可知学习的相关性：对于任何单一假设 h ， $P(\text{error}_{\text{true}}(h) \geq \epsilon)$

$$P(\text{error}_{\text{true}}(h) \geq \epsilon) \leq e^{-2m\epsilon^2}$$

- 但我们必须考虑 H 中的所有假设

$$P(\exists h \in H | \text{error}_{\text{true}}(h) \geq \epsilon) \leq |H| e^{-2m\epsilon^2}$$

- 因此，每个 h 满足以下条件时，概率至少为 $1 - \delta$

$$\text{error}_{\text{true}}(h) \leq \frac{\ln |H| + \ln \frac{1}{1-\delta}}{2m}$$



- 当估计参数 ϑ 时, 在 a 、 b 范围内, 基于 m 个样本

$$\Pr(|\hat{\vartheta} - \vartheta| \geq \epsilon) \leq \exp(-\frac{2m\epsilon^2}{(b-a)\epsilon^2})$$

- 当估计概率 ϑ 位于 $[0, 1]$ 内时, 因此

$$\Pr(|\hat{\vartheta} - \vartheta| \geq \epsilon) \leq \exp(-\frac{2m\epsilon^2}{1})$$

- 若仅关注单边误差, 则

$$\Pr(\hat{\vartheta} - \vartheta \geq \epsilon) \leq \exp(-\frac{2m\epsilon^2}{1})$$



$$m \frac{1}{2\epsilon^2} \ln |H| \quad \ln p\{ \delta q$$

此处 ϵ 是输出假设的训练误差与真实误差之间的差值（对 H 中所有 h 均成立）

然而，训练误差最低的 输出 h 未必能提供 真实误差最低的 h

真实误差最低的 h 。 h 的真实误差与 h 的真实误差之间可能存在多大偏差？



$$\frac{1}{m} \sum_{q=1}^m \ln |H| \leq \ln p\{ \epsilon_q \leq \epsilon \}$$

此处 ϵ 是输出假设的训练误差与真实误差之间的差值（对 H 中所有 h 均成立）

然而，训练误差最小的输出 h 未必能提供真实误差最低的 h

具有最低真实误差的 h 。 h 的真实误差与 h 的真实误差之间可能存在多大差异？

$$\text{error}_{\text{true}}(h_q) - \min_{h \in H} \text{error}_{\text{true}}(h) \leq 2\epsilon$$

- h 最佳训练误差假设
- h 最优真实误差假设



$$m \frac{1}{2\epsilon^2} \ln |H| + \ln p\{ \delta \leq \epsilon \}$$

问题：对于正则化哈伯德模型 () 的正则化哈伯德模型 $(\theta|h: X \rightarrow Y^u)$ ，若 $|H|$ 为无穷大，我们应采用何种复杂度度量来替代 $|H|$ ？



$$m \frac{1}{2\epsilon^2} \ln |H| + \ln p1\{\delta q$$

问题：对于 $H = \{h : X \rightarrow Y\}$ ，若 $|H|$ 为无穷大，我们应采用何种复杂度度量来替代 $|H|$ ？

答案： X 的最大子集，对于该子集， H 能够保证零训练误差（无论其标签如何）。



$$m \frac{1}{2\epsilon^2} (\ln |H| + \ln \frac{1}{\delta})$$

问题：对于 $H = \{h : X \rightarrow \mathcal{Y}\}$ ，若 $|H|$ 为无穷大，应采用何种复杂度度量替代 $|H|$ ？

答案： **H** 能保证零训练误差的**最大子集**（无论其标签如何）

H 的**VC**维度即该子集的大小。

问题: 若 $H = \{h: X \rightarrow Y\}$ 为无限集, 我们应采用何种复杂度度量替代 $|H|$?

答案: H 能保证零训练误差的 X 的最大子集 (无论其标签如何)

非正式直观理解:

- 决策树示例: 需要观察多少标签才能学习

h ?



二分法：集合 S 的二分法是将 S 划分为两个不相交的子集。


二分法：将集合 S 的每个元素标记为正或负的过程。

碎裂：若对于集合 S 的任意二分法，均存在 H 中与该二分法相容的假设，则称假设空间
 H 使 S 碎裂。



瓦普尼克-切尔沃嫩斯基维度 (VC_{Hq}) 是假设空间 $\mathcal{H}$ 在实例空间 X 上的维度, 定义为 $\mathcal{H}$ 所能击碎的 X 中最大有限子集的大小。若 $\mathcal{H}$ 能击碎任意大的 X 的有限子集, 则 $VC_{\mathcal{H}q} = \infty$ 。


$$VC(\mathcal{H}) = \max\{m : \Pi_{\mathcal{H}}(m) = 2^m\}$$



存在这样的集合, 其 $2^3 = 8$ 种对分均可被线性划分实现

(a) 示例集大小为 3

假设空间不能实现所有的对分



对任何集合, 其 $2^4 = 16$ 种对分中至少有一种不能被线性划分实现

(b) 示例集大小为 4



随机抽取多少个样本足以以概率至少 $1 - \delta$ 耗尽 $V(S_{H,D})$?

即：保证任何完美契合训练数据的假设，其正确概率 $1 - \delta$ 约为 ϵ

$$m \geq \frac{1}{\epsilon} (4 \log_2 \frac{1}{\delta} + 8VC(H) \log_2 \frac{1}{\epsilon})$$

与我们基于 $|H|$ 的先前结果比较：

$$m \geq \frac{1}{\epsilon} (\ln \frac{1}{\delta} + \ln |H|)$$