

注意力机制与Transformers模型

机器学习（双语）

费琪 (fred.qi@ieee.org)

杨莉

2023年11月

人工智能学院

西安电子科技大学





词嵌入变换器

视觉Transformer模型

词嵌入



词嵌入是一种通过学习获得的文本表示形式，其中具有相同含义的词汇具有相似的表示形式。

采用稠密低维向量的优势之一在于计算效率：

- 大多数神经网络工具包难以高效处理高维稀疏向量。
- 稠密表示的核心优势在于泛化能力

(1) 《自然语言处理中的神经网络方法》，2017年，第92页



词袋模型 (BOW) 是一种将任意文本转换为

固定长度向量，通过统计每个词出现的次数。

该过程常被称为向量化。



词袋模型 (BOW) 是一种将任意文本转换为


固定长度的向量，通过统计每个词出现的次数。

该过程通常被称为向量化。

示例

文档	the	猫	坐	在	帽子	里
猫坐在	1	1	1	0	0	0
猫坐在帽子里	2	1	1	1	1	0
戴帽子的猫	2	1	0	0	1	1


²<https://victorzhou.com/blog/bag-of-words/>



CBOW

Word2Vec是一种统计方法，用于从文本语料库中高效学习独立的词嵌入。

³ T. Mikolov 等, ICLR 2013; T. Mikolov 等, NIPS 2013。



Word2Vec是一种统计方法，用于从文本语料库中高效学习独立的词嵌入。

跳跃词模型旨在最大化平均对数概率

$$\frac{1}{T} \sum_{t=1}^T \sum_{-c \leq j \leq c, j \neq 0} \log p(w_{t+j} | w_t)$$

基本跳跃词模型通过最大化函数定义：


使用softmax函数：

$$p(w_o | w) = \frac{\exp(v_w' v_{w_o})}{\sum_{w=1}^W \exp(v_w' v_w)}$$

⁴ T. Mikolov 等, ICLR 2013; T. Mikolov 等, NIPS 2013.




主成分分析法投影的国家与首都向量



$\text{vec}(\text{'马德里'}) - \text{vec}(\text{'西班牙'}) + \text{vec}(\text{'法国'})$

⁵ T. Mikolov 等, ICLR 2013; T. Mikolov 等, NIPS 2013.


变压器





- 我游过河到达对岸。
- 我穿过马路去银行取现金。


示意图展示注意机制：词语"河"与"游过"影响了对"岸"的词义解读。

注意：学习到的注意力权重示例。





⁶ D. Bahdanau, K. Cho, and Y. Bengio, "Neural machine translation by jointly learning to align and translate", ICLR 2015.



上下文向量 c_i 由此作为这些标注 h_j 的加权和计算得出：

$$c_i = \sum_{j=1}^x \alpha_{ij} h_j .$$

每个注释 h_j 的权重 α_{ij} 通过以下方式计算：

$$\alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{k=1}^{Tx} \exp(e_{ik})} ,$$

其中 $e_{ij} = a(s_{i-1}, h_j)$ 且：

$$h_t = f(x_t, h_{t-1})$$

$$c = q(((\{ h_1, \dots, h_{T_x} \}))$$




在编码器-解码器框架中，编码器将输入句子（向量序列 $\mathbf{x} = (x_1, \dots, x_{T_x})$ ）转换为向量 c 。其中：

$$h_t = f(x_t, h_{t-1})$$

$$c = q((h_1, \dots, h_{T_x}))$$

通过将前向隐含状态

$$\vec{h}_j \text{ 与后向隐状态 } \overleftarrow{h}_j \text{ 进行拼接，即 } h_j = [\vec{h}_j; \overleftarrow{h}_j]^\top。$$




A. Vaswani等人,《注意力即一切》,NIPS 2017。编码器:

$N=6$ 层相同结构。

- 多头自注意力机制,
- 基于位置的全连接前馈网络


解码器: $N=6$ 个相同的层

- 对编码器堆栈输出进行多头注意力机制




该注意力机制称为“缩放点积注意力”：

注意力 QKV
(,,)




$$= \text{softmax}^{(QK^T)} \frac{V}{\sqrt{d_k}}$$



该注意力机制被称为“缩放点积注意力”：
 注意 $QKV = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V$

$$\begin{matrix} \text{[Red Box]} \\ \text{Y} \\ N \times D_v \end{matrix} = \text{Softmax} \left\{ \begin{matrix} \text{[Red Box]} \\ \text{QK}^T \\ N \times N \end{matrix} \right\} \times \begin{matrix} \text{[Red Box]} \\ \text{V} \\ N \times D_v \end{matrix}$$

$\sqrt{d_k}$



多头注意力

我们发现，将查询、键和值分别通过不同的学习线性投影进行 h 次线性投影至 d_k 、 d_k 和 d_v 维度，能带来显著益处。

多头注意力机制使模型能够同时关注不同位置来自不同表示子空间的信息。




位置级前馈网络

$$\text{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2$$

嵌入与Softmax

我们使用学习到的嵌入将输入令牌和输出令牌转换为维度为 $d_{\text{模型}}$ 的向量。



位置编码


为了使模型能够利用序列的顺序，我们必须注入一些关于令牌在序列中相对或绝对位置的信息

$$PE_{(\text{pos}, 2i)} = \sin(\text{pos}/10000^{2i/d_{\text{模型}}})$$


$$PE_{(\text{pos}, 2i+1)} = \cos(\text{pos}/10000^{2i/d_{\text{模型}}})$$

视觉变换器


Vision Transformer (ViT)




Transformer Encoder




⁷ A. Dosovitskiy 等, "一张图片值16×16个词: 大规模图像识别的Transformers模型", ICLR 2021.



Swin Transformer通过合并深层图像块（灰色区域）构建分层特征图，由于仅在局部窗口（红色区域）内进行自注意力计算，其计算复杂度与输入图像尺寸呈线性关系。




图示说明了在提出的Swin Transformer架构中计算自注意力时采用的移位窗口方法。在 第 l 层（左侧），采用常规窗口划分方案，并在每个窗口内计算自注意力。在下一层 $l+1$ （右侧），窗口划分发生移位，从而形成新的窗口。



(a) Swin Transformer (Swin-T) 的架构;

(b) 两个连续的Swin Transformer模块。

W-MSA与SW-MSA分别是采用常规窗口配置与偏移窗口配置的多头自注意力模块。



在移位窗口划分中实现自注意力的高效批量计算方法示意图。

ImageNet-22K预训练模型


方法	图像	参数数	浮点运算次数	吞吐量	top1准确率
R-101x3	384^2	388M	204.6G	-	84.4
R-152x4	480^2	937M	840.5G	-	85.4
ViT-B/16	384^2	86M	55.4G	85.9	84.0
ViT-L/16	384^2	307M	190.7G	27.3	85.2
Swin-B	224^2	88M	15.4G	278.1	85.2
Swin-B	384^2	88M	47.0G	84.7	86.4
Swin-L	384^2	197M	103.9G	42.1	87.3

Swin Transformer实现了显著优化的速度-精度权衡：

Swin-B 模型在 **top-1** 准确率上达到 **86.4%**，比 ViT 模型高出 **2.4%**，且在类似推理吞吐量和略低的浮点运算次数下实现该性


斯温变压器

能。Swin-L 模型比 Swin-B 模型提升 0.9%。




检测变换器（DETR）通过将通用卷积神经网络与变换器架构相结合，直接（并行）预测最终检测结果集。训练过程中，二分匹配将预测结果与真实目标边界框进行唯一对应。未匹配的预测应输出“无目标”（ Φ ）类别预测。

⁹ N. Carion 等, "基于Transformers的端到端目标检测", ECCV 2020。




DETR采用传统的卷积神经网络（CNN）骨干结构来学习输入图像的二维表示。模型将其展平并补充位置编码后，再传递至Transformer编码器。Transformer解码器则以少量固定数量的学习位置嵌入（我们称之为目标查询）作为输入，同时关注编码器输出。我们将解码器的每个输出嵌入传递至共享的前馈网络（FFN），该网络预测检测结果


（包含类别与边界框）或“无目标”类别。



- 编码器对一组参考点的自我注意力机制。
- 编码器能够分离各个实例。使用基线DETR在验证图像上进行的预测。



在长训练计划基准模型中，各解码层后的AP和AP50性能。DETR设计上无需NMS，本图验证了这一特性。NMS在末层降低AP（移除TP预测），但在前层提升AP——而DETR不具备移除重复预测的能力。



¹⁰ C. Yang 等, "BEVFormer v2: 通过透视监督将现代图像骨干网络适配至鸟瞰图识别", CVPR 2023.