

# 生成模型

## 机器学习（双语）

---

2025年12月9日

人工智能学院

西安电子科技大学






引言

基于似然模型的隐式生成模型

前沿技术    总结

## 引言

---



### 理查德·费曼

我无法创造的事物，  
便无法理解。

- **目标：**学习数据真实的底层分布  $p_{data}(x)$ ，以生成新的、真实的样本。
- **关键应用：**
  - 图像合成（如人脸、卧室场景）
  - 文本转语音（如WaveNet）
  - 超分辨率与图像修复
  - 深度伪造与内容创作




## 判别模型

- 学习条件概率  $P(Y/X)$ 。
- 重点：寻找类别的决策边界。
- 示例：将图像分类为猫或狗。


## 生成模型


- 学习联合概率  $P(X, Y)$  或分布  $P(X)$ 。
- 重点：理解数据的生成方式。
- 洞见：若能生成数据，便能理解其结构。





- **判别模型：**建模 *条件概率*  $P(Y|X)$ ——优化预测/分类任务。
- **生成模型：**建模联合 *概率*  $P(X, Y)$ 或数据分布  $P(X)$ ——**支持采样**、密度估计及数据理解。
- **应用场景：**
  - **采样/内容合成：**生成逼真的图像、音频、文本。
  - **密度估计/异常检测：**评估样本的概率。
  - **插值与反问题：**填补缺失数据，解决反问题任务。
  - **半监督/自监督学习：**利用  $P(X)$ 处理无标签数据。





AR自回归模型 (例如PixelRNN、PixelCNN)

概率主成分分析 (PPCA)

变分自编码器 (VAE)



# 生成模型的分类学

GAN 生成对抗网络

## 基于似然模型的方法

---



**概率主成分分析 (Probabilistic PCA)** 是一种受限的高斯分布形式，其中自由参数的数量可以受到限制，同时仍能使模型捕捉数据集中的主导相关性。

- 概率PCA可用于建模类条件密度分布，从而应用于分类问题。
- 概率PCA模型可通过生成式运行，从而从分布中提供样本。
- 概率PCA是**线性高斯**框架的简单示例，其中所有边缘分布和条件分布均为高斯分布。



- 首先引入与主成分空间对应的**显式潜在变量**  $\mathbf{z}$ 。
- 接着定义隐变量的高斯先验分布  $p(\mathbf{z})$ ,


$$p(\mathbf{z}) = N(\mathbf{z} | \mathbf{0}, \mathbf{I}),$$

- 同时为观测变量  $\mathbf{x}$  定义高斯条件分布  $p(\mathbf{x} | \mathbf{z})$ , 该分布取决于潜在变量的值。

$$p(\mathbf{x} | \mathbf{z}) = N(\mathbf{x} | \mathbf{W}\mathbf{z} + \boldsymbol{\mu}, \sigma^2 \mathbf{I})$$

- 我们可以从生成模型的角度看待概率PCA模型, 因此

$$\mathbf{x} = \mathbf{W}\mathbf{z} + \boldsymbol{\mu} + \boldsymbol{\epsilon}.$$



概率PCA模型的生成视图，适用于二维数据空间与一维潜在空间。观测数据点 $\mathbf{x}$ 的生成过程如下：首先从潜在变量的事先分布 $p(\hat{z})$ 中抽取值 $\hat{z}$ ，随后从具有均值 $\hat{z}w + \mu$ 及协方差 $\sigma^2=I$ 的各向同性高斯分布（红色圆圈所示）中抽取 $\mathbf{x}$ 的值。

绿色椭圆表示边缘分布 $p(\mathbf{x})$ 的密度等值线。



- 假设我们希望通过最大似然法确定参数 $\mathbf{W}$ 、 $\mu$ 和 $\sigma^2$ 的取值。
- 我们需要求解边缘分布 $p(\mathbf{x})$ 的表达式：

$$p(\mathbf{x}) = \int p(\mathbf{x}|\mathbf{z})p(\mathbf{z}) \, d\mathbf{z} = N(\mathbf{x}|\mu, \mathbf{C}),$$

其中  $d \times d$  协方差矩阵  $\mathbf{C}$  定义为

$$\mathbf{C} = \mathbf{W}\mathbf{W}^T + \sigma^2\mathbf{I}_o$$



- 计算预测分布时，需求解  $\mathbf{C}^{-1}$ ，这涉及  $d \times d$  矩阵的求逆运算。
- 利用矩阵逆矩阵恒等式，我们得到

$$\mathbf{C}^{-1} = \sigma^{-2} \mathbf{I} - \sigma^{-2} \mathbf{W} \mathbf{M}^{-1} \mathbf{W}^T,$$

其中  $d' \times d'$  矩阵  $\mathbf{M}$  定义为

$$\mathbf{M} = \mathbf{W}^T \mathbf{W} + \sigma^2 \mathbf{I}_o$$

- 后验分布  $p(\mathbf{z}|\mathbf{x})$  由下式给出：

$$p(\mathbf{z}|\mathbf{x}) = N(\mathbf{z} | \mathbf{M}^{-1} \mathbf{W}^T (\mathbf{x} - \boldsymbol{\mu}), \sigma^{-2} \mathbf{M}).$$




## 自回归模型 (AR)

### 核心原则

使用概率链式法则分解联合分布。

$$p(x) = \prod_{i=1}^n p(x_i | x_1, \dots, x_{i-1})$$



### 架构:

- **RNNs:** 序列数据 (文本、音频)。
- **像素递归神经网络/像素卷积神经网络:** 逐像素生成图像。


### 优缺点

**优点:** 精确似然计算 (可处理)。易于训练。


**缺点:** 序列生成计算效率较低。




## 自回归模型 (AR) : 像素递归神经网络/像素卷积神经网络




像素卷积神经网络



行LSTM



对角双向LSTM




- 为清晰起见，省略了表示偏置参数的链接。
  - 具有两层权重的自关联多层感知器。
  - 该网络通过最小化均方误差，被训练为将输入向量映射到其自身。
- 平方和误差

$$E(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \|y(\mathbf{x}_n, \mathbf{w}) - \mathbf{x}_n\|^2$$

- 即使在隐藏层中存在非线性单元，这样的网络也相当于线性PCA。

<sup>1</sup> Hinton 和 Zemel, NIPS 1993。



添加额外的非线性隐藏层可形成自关联网络，该网络能够执行非线性降维。

## 变分自编码器（VAEs）

- 引入潜在变量  $z$  以捕捉变异因素（姿态、光照等）。
- 编码器  $q_\phi(z/x)$ ：将输入映射至潜在空间。
- 解码器  $p_\theta(x/z)$ ：从潜在空间重建输入。



我们无法直接优化不可处理的似然函数。取而代之的是，我们最大化

证据下界（ELBO）：

$$\log p(x) \geq \underbrace{\mathbb{E}_{q_\phi(z|x)} [\log p_\theta(x/z)]}_{\text{重构 + 构造损失}} - \underbrace{D_{KL}(q_\phi(z|x) // p(z))}_{\text{正则项}}$$

### 权衡



**优点：**原理性方法，可解释的潜在空间。

**缺点：**生成的图像常模糊（源于L2重建损失与高斯分布假设）。

**动机:** VAE中的连续潜在空间可能导致模糊输出。

**VQ-VAE:** 采用离散编码本进行潜在变量嵌入。编码器将输入映射至最近的编码本向量。

解码器根据选定编码本向量重建输入。



## 隐式生成模型

---



- **核心原理：**博弈论方法（最小最大博弈）。
- 两个神经网络相互竞争：


## 生成器 (G)

试图生成逼真的伪数据以欺骗判别器。

$$z \rightarrow G(z)$$

## 鉴别器 (D)

试图区分真实数据 ( $x$ ) 与伪造数据 ( $G(z)$ ) 。



生成器与判别器进行一场最小最大博弈，其价值函数为  $V(G, D)$ :

$$\min_G \max_D V(G, D) = \mathbb{E}_{x \sim p_{\text{数据}}} [\log D(x)] + \mathbb{E}_{z \sim p_z} [\log(1 - D(G(z)))]$$

- **优点:** 生成非常清晰、高质量的图像。
- **缺点:** 训练过程不稳定（纳什均衡点难以确定）；模式坍缩；无显式似然密度函数。



## 尖端技术

---




现代生成式AI的主流范式（如Stable Diffusion、DALL-E）。

- **前向过程（固定）**：逐步向数据添加高斯噪声直至完全转化为纯噪声（ $x_T$ ）。



- **逆向过程（学习型）**：训练神经网络对图像进行**序列降噪**。



**优势**：相较于生成对抗网络（GANs），具有更高的样本质量和训练稳定性。

## 总结

---



| 模型     | 类型      | 优点          | 缺点      |
|--------|---------|-------------|---------|
| 自回归    | 显式（可处理） | 精确似然        | 采样速度慢   |
| 变分自编码器 | 显式（近似）  | 快速采样，平滑潜在变量 | 模糊样本    |
| 生成对抗网络 | 隐式      | 锐利样本        | 不稳定训练   |
| 扩散     | 显式（近似）  | 高质量，稳定      | 慢采样（迭代） |