

概率论

机器学习（双语）

齐飞 (Fei **Qi**) xfred.qi@ieee.org

李阳 (Yang **Li**)

2023年10月

人工智能学院
西安电子科技大学





概率论二元变量

多元二项变量高斯分布贝叶

斯定理

概率论



随机变量

随机变量是指能够随机取不同值的变量。

概率分布

概率分布描述了随机变量或随机变量集合出现其每个可能状态的可能性。



- 离散变量的概率分布可使用概率质量函数（PMF）描述。
- $P(p_X, q)$
- $P(p_X, q) = P(p_X = x, q)$ 或 $x = P(p_X, q)$
- 联合概率分布, $P(p_X, y, q) = P(p_X = x, Y = y, q)$

概率质量函数的性质

- 概率分布 P 的定义域必须是变量 x 的所有可能状态集合。
- $\sum_x P(p_X, q) = 1$
- $\sum_x P(p_X, q) = 1$



- 连续变量
- 概率 p 的定义域必须是变量 X 的所有可能状态的集合。
- $\int_{-\infty}^{\infty} p(x) dx = 1$
- $p(x) \geq 0$



子集上的概率分布称为边缘
概率分布。

- 假设我们有离散随机变量 X 和 Y ，且已知 $P_{pX, Y}(\mathbf{q})$ 。可通过求和规则求得 $P_{pX}(\mathbf{q})$:

$$P_{pX}(\mathbf{q}) = \sum_y P_{pX, Y}(\mathbf{q})$$

- 对于连续变量，我们需要用积分代替求和：

$$P_{pX}(\mathbf{q}) = \int P_{pX, Y}(\mathbf{q}) dy$$



- 我们关注某个事件发生的概率，前提是另一个事件已经发生。
- 我们用以下公式表示事件 Y 在事件 X 发生时的条件概率： $P(Y=y \text{ given } X=x)$
 $P(Y=y|X=x)$ 。
- 其计算公式为：

$$P(Y=y|X=x) = \frac{P(Y=y, X=x)}{P(X=x)}$$



- 任何涉及多个随机变量的联合概率分布，均可分解为仅涉及单个变量的条件分布：

$$P(pX_1, \dots, X_n) = \prod_{i=1}^n P(pX_i | X_1, \dots, X_{i-1})$$

- 该观察结果被称为概率的链式法则或乘积法则。

例

$$P(p, a, b, c, q) = P(p|a, b, c, q) P(a|b, c, q) P(b|c, q) P(c|q) \\ P(p, a, b|c, q) = P(p|a, b, c, q) P(a|b, c, q) P(b|c, q)$$



- 两个随机变量 X 和 Y 相互独立，当且仅当它们的概率分布可表示为两个因子乘积的形式，其中一个因子仅涉及 X ，另一个因子仅涉及 Y ：

$$p_{X,Y}(x,y) = p_X(x) p_Y(y)$$



- 若对于任意随机变量 z 的取值, X 与 Y 的条件概率分布均能按此方式分解, 则称随机变量 X 和 Y 在 z 条件下相互独立:

$$P_{X,Y|Z} = P_{X|Z} P_{Y|Z}$$

$$p_{X,Y|Z}(x,y|z) = p_{X|Z}(x|z) p_{Y|Z}(y|z)$$



函数 $f(x)$ 关于概率分布 $P(X)$ 的期望值，即当 x 从 $P(X)$ 中抽取时 f 所取值的平均值。

- 对于离散变量：

$$E_{xP} [f(x)] = \sum_x P(x) f(x)$$

- 对于连续变量：

$$E_{xP} [f(x)] = \int p(x) f(x) dx$$



函数 f 关于概率分布 P_X 的期望值或预期值，是指当 x 从 Ω 中抽取时 f 所取值的平均值或均值。

- 对于离散变量：

$$E_{xP} [f(x)] = \sum_x P(x) f(x)$$

- 对于连续变量：

$$E_{xP} [f(x)] = \int p(x) f(x) dx$$

- 期望呈线性关系：

$$E[\alpha f(x) + \beta g(x)] = \alpha E[f(x)] + \beta E[g(x)]$$



方差衡量函数不同值的分散程度：

$$\text{方差} = \mathbb{E}[(f(\mathbf{x}) - \mathbb{E}[f(\mathbf{x})])^2]$$

- 方差的平方根称为标准差。



协方差可反映两个值之间线性相关程度：

$$\text{Cov}(f(\mathbf{x}), g(\mathbf{y})) = E[f(\mathbf{x})g(\mathbf{y})] - E[f(\mathbf{x})]E[g(\mathbf{y})]$$



协方差可反映两个值之间线性相关程度：

$$\text{Cov}(f(x), g(y)) = E[f(x)g(y)] - E[f(x)]E[g(y)]$$

随机向量 $x \in \mathbb{R}^n$ 的协方差矩阵是一个 $n \times n$ 矩阵：

$$x \in \mathbb{R}^n, \quad \text{Cov}(x)_{i,j} = \text{Cov}(x_i, x_j)$$

二进制变量



- 抛硬币：正面=1，反面=0

$$p(x=1|\mu) = \mu$$

- 伯努利分布

$$\begin{aligned} \text{Bern}(x|\mu) &= \mu^x (1-\mu)^{1-x} \\ \mathbb{E}[x] &= \mu \\ \text{var}[x] &= \mu(1-\mu) \end{aligned}$$




- N 次抛硬币

每百万次正面 $N, \mu q$

- 二项分布

$$\begin{aligned}
 & \text{二项分布 } N, \mu q \\
 & \text{Bin } m \ N, \mu \\
 & \text{varrms} \\
 & \text{Ermsq} \\
 & \text{Bin } pm \ N, \mu q
 \end{aligned}$$





伯努利分布的最大似然法 (ML)

- 已知数据集 $x_1, \dots, x_N$ μ 表示正面 (1) , $1 - \mu$ 表示反面 (0)

$$p(D|\mu) = \prod_{n=1}^N p(x_n|\mu) = \mu^{x_n} (1-\mu)^{1-x_n}$$

$$\ln p(D|\mu) = \sum_{n=1}^N \ln p(x_n|\mu)$$

$$= \sum_{n=1}^N [x_n \ln \mu + (1-x_n) \ln (1-\mu)]$$

$$\mu_{ML} = \frac{1}{N} \sum_{n=1}^N x_n = \frac{m}{N}$$



示例：

$$D = \{t_1, 1, \mathbf{1}\} \quad \mu_{ML} = \frac{3}{3} = 1$$

预测：所有未来的抛掷都会出现正面朝上。

对 D 的过拟合



分布在 $\mu \in (0, 1)$ 上。

$$\begin{aligned}
 \text{贝塔分布} & \propto \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} \mu^{a-1} (1-\mu)^{b-1} \\
 E[\mu] &= \frac{a}{a+b} \\
 \text{var}(\mu) &= \frac{ab}{(a+b)^2(a+b+1)}
 \end{aligned}$$



$$\Gamma(p) = \int_0^{\infty} x^{p-1} e^{-x} dx$$

属性

$$\Gamma(p+1) = p \Gamma(p)$$

当 $p=1$ 时,

$$\Gamma(n) = (n-1)! \quad (n=1, 2, 3, \dots)$$



$$p(\mu | a_0, b_0, D) \propto p(D | \mu) p(\mu | a_0, b_0)$$





$$\propto \prod_{n=1}^N \mu^{x_n} (1-\mu)^{1-x_n} \text{贝塔}(\mu | a_0, b_0)$$




$$\propto \mu^{a_0 + \sum_{n=1}^N x_n} (1-\mu)^{b_0 + \sum_{n=1}^N (1-x_n)}$$

$$\propto \text{贝塔}(\mu | a_N, b_N)$$

$$a_N = a_0 + m, \quad b_N = b_0 + pN - m$$

贝塔分布为伯努利分布提供了共轭先验。







随着数据集规模 N 的增大

$$\begin{aligned}
 \text{Er} &= \frac{a_N}{b_N} \frac{m}{a_N^N} \frac{m}{m} \frac{m}{\mu} \mu^{ML} \\
 \text{var} \mu &= \frac{a_N}{pa_N} \frac{b_N}{b_N q 2 pa_N} \frac{N}{b_N} \frac{1}{b_N} \frac{1}{q} 0
 \end{aligned}$$



下次抛硬币出现正面朝上的概率是多少？

$$p(x|a_0, b_0, D) = \int_0^1 p(x|\mu) q(\mu|a_0, b_0, D) d\mu$$

$$= \int_0^1 \mu p(x|\mu) q(\mu|a_0, b_0, D) d\mu$$

$$= \text{Er} \mu | a_0, b_0, D$$

多项式变量



1-of-K编码方案:

$$\begin{aligned}
 x &= [0, 0, 1, 0, 0, 0] q^T \\
 p_{px|\mu q} &= \prod_{k=1}^K \mu_k^{x_k}, \quad @k: \mu_k = 0 \text{ 且 } \prod_{k=1}^K \mu_k = 1 \\
 E_{rx|\mu s} &= p_{px|\mu q x} = p_{\mu, 1, \dots, \mu} q^T = \mu \\
 p_{px|\mu q} &= \prod_{k=1}^K \mu_k = 1
 \end{aligned}$$



已知: $D = \{x_1, \dots, x_N\}$

$$p(\mathbf{D} | \boldsymbol{\mu}) = \prod_{n=1}^N \prod_{k=1}^K p(x_{nk} | \mu_k) = \prod_{k=1}^K \mu_k^{n_k} (1 - \mu_k)^{m_k}$$


确保 $\mu_k \in [0, 1]$, 使用拉格朗日乘子 λ 。

$$L(\boldsymbol{\mu}, \boldsymbol{\lambda}) = \sum_{k=1}^K m_k \ln \mu_k - \lambda \left(\sum_{k=1}^K \mu_k - 1 \right)$$

$$\frac{\partial L}{\partial \mu_k} = \frac{m_k}{\mu_k} - \lambda = 0 \Rightarrow \mu_k = \frac{m_k}{N} \quad \text{ML}$$




$$\begin{aligned}
 & \text{Mult}(\mathbf{p}_1, \mathbf{p}_2, \dots, \mathbf{p}_K) \mid \boldsymbol{\mu}, N, \mathbf{q} \\
 & \quad \mathbf{p}_1, \mathbf{p}_2, \dots, \mathbf{p}_K \sim \text{Dir}(\boldsymbol{\mu}) \\
 & \quad \mathbf{p}_k \sim \text{Dir}(\boldsymbol{\mu}_k) \\
 & \quad \mathbf{p}_k \sim \text{Dir}(\boldsymbol{\mu}_k) \\
 & \quad \mathbf{p}_k \sim \text{Dir}(\boldsymbol{\mu}_k)
 \end{aligned}$$




参数 μ_k 的先验分布 U :

$$p(\mu | \alpha) \propto \prod_{k=1}^K \mu_k^{\alpha_k - 1}$$




参数 μ_k 的先验分布 U :

$$p(\mu | \alpha) = \frac{\Gamma(\alpha_0)}{\Gamma(\alpha_1) \cdots \Gamma(\alpha_K)} \prod_{k=1}^K \mu_k^{\alpha_k - 1}$$



参数 μ_k 的先验分布 u :

$$\text{Dir}(\mu | \alpha) = \frac{\Gamma(\alpha_0) \prod_{k=1}^K \mu_k^{\alpha_k - 1}}{\Gamma(\alpha_1) \Gamma(\alpha_2) \dots \Gamma(\alpha_K)}$$



参数 μ_k 的先验分布 u :

$$p(\mu | \alpha) = \frac{\Gamma(\alpha_0)}{\Gamma(\alpha_1) \cdots \Gamma(\alpha_K)} \prod_{k=1}^K \mu_k^{\alpha_k - 1}$$




多项式分布的共轭先验。




$$p(\mu|D, \alpha) \propto \prod_{k=1}^K \prod_{i=1}^{m_k} p(D_{ki}|\mu_k) p(\mu_k|\alpha_k)$$

$$p(\mu|D, \alpha) \propto \text{Dir}(\mu|\alpha) \prod_{k=1}^K \prod_{i=1}^{m_k} p(D_{ki}|\mu_k)$$

从左至右, α_k 分别等于 10^{-1} 、 10^0 和 10^1 。



高斯分布






$$p(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{x-\mu}{2\sigma^2}\right)$$




N 个独立同分布随机变量的和分布


随着 N 的增大，其分布趋向于正态分布。示例： N 个服

从均匀分布 $(0,1)$ 的随机变量。





$$p(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{2\pi |\boldsymbol{\Sigma}|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right\}$$



$$\Delta^2 = \mu^T \Sigma^{-1} \mu$$

$$\Sigma^{-1} = \sum_{i=1}^D \frac{1}{\lambda_i} u_i u_i^T$$

$$\Delta^2 = \sum_{i=1}^D \frac{y_i^2}{\lambda_i}$$

$$y_i = u_i^T (x - \mu)$$



$$E_{rxs} = \frac{1}{2} \frac{1}{p \pi q D^2 |\Sigma|^{1/2}} \exp \left\{ -\frac{1}{2} \mu^T \Sigma^{-1} \mu \right\} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \frac{1}{2} z^T \Sigma^{-1} z p z \mu q dz$$




由于 z 的反对称性

$$E_{rxs} = \mu$$



$$E\mathbf{r}\mathbf{r}\mathbf{x}^T = \mathbf{S} = \mathbf{\mu}\mathbf{\mu}^T + \mathbf{\Sigma}$$

$$\text{cov}(\mathbf{r}\mathbf{x}_s) = E[\mathbf{p}\mathbf{x}_s \mathbf{r}\mathbf{x}_s \mathbf{q}\mathbf{p}\mathbf{x}_s] = \mathbf{E}\mathbf{r}\mathbf{x}_s \mathbf{q}\mathbf{p}\mathbf{x}_s^T = \mathbf{\Sigma}$$





$$p(x) = \mathcal{N}(x|\mu, \Sigma)$$

$$x = \begin{bmatrix} x_a \\ x_b \end{bmatrix}, \quad \mu = \begin{bmatrix} \mu_a \\ \mu_b \end{bmatrix}, \quad \Sigma = \begin{bmatrix} \Sigma_{aa} & \Sigma_{ab} \\ \Sigma_{ba} & \Sigma_{bb} \end{bmatrix}$$

$$\Lambda = \Sigma^{-1} = \begin{bmatrix} \Lambda_{aa} & \Lambda_{ab} \\ \Lambda_{ba} & \Lambda_{bb} \end{bmatrix}$$



分区条件式

$$p(x_a|x_b) = N(x_a|\mu_a, \Sigma_{a|b})$$



$$\begin{aligned} \Sigma_{a|b} &= \Lambda_{aa}^{-1} - \Sigma_{aa}^{-1} \Sigma_{ab} \Sigma_{bb}^{-1} \Sigma_{ba} \\ \mu_{a|b} &= \Sigma_{a|b} \Lambda_{aa} \mu_a + \Lambda(ab) p x_b - \mu_b \end{aligned}$$

分区边缘分布

$$p(x_a) = \int p(x_a, x_b) dx_b = N(x_a|\mu_a, \Sigma_{aa})$$



分区条件分布与边缘分布





给定独立同分布数据 $x_1, \dots, x_N$ 对数似然函数定义如下：

$$\ln p(X|\mu, \Sigma) = -\frac{ND}{2} \ln | \Sigma | - \frac{1}{2} \sum_{n=1}^N (x_n - \mu)^T \Sigma^{-1} (x_n - \mu)$$

充分统计量

$$\sum_{n=1}^N x_n, \sum_{n=1}^N x_n x_n^T$$



将对数似然函数的导数设为零

$$\frac{\partial}{\partial \mu} \ln p(X|\mu, \Sigma) = \sum_{n=1}^N \frac{1}{\sigma^2} (x_n - \mu) = 0$$

并求解得到

$$\mu_{\text{ML}} = \frac{1}{N} \sum_{n=1}^N x_n$$

同理

$$\Sigma_{\text{ML}} = \frac{1}{N} \sum_{n=1}^N (x_n - \mu_{\text{ML}})(x_n - \mu_{\text{ML}})^T$$



在真实分布下

$$\begin{aligned} E \mu_{\text{ML}} &= \mu \\ E \Sigma_{\text{ML}} &= \frac{N-1}{N} \Sigma \end{aligned}$$

因此定义

$$p(\mathbf{q} | \Sigma(\text{ML})) = \frac{1}{N} \prod_{n=1}^N p(x_n | \mu_{\text{ML}}, \Sigma(\text{ML}))$$

贝叶斯定理



- 已知 P_{yx} ，需求 P_{xy} 。若已知 P_x ，可通过贝叶斯定理计算目标量：

$$P_{y|q} = \frac{P_{pxq} P_{py|xq}}{P_{pyq}}$$

- 我们无需从对 P_{pyq} 的认知开始，因为

$$P_{pyq} = \sum_x P_{py|xq} P_{pxq}$$



- 已知 $P(y|x)$, 需知 $P(x|y)$ 。若已知 $P(x)$, 可通过贝叶斯定理计算目标 $P(y)$:

$$P(x|y) = \frac{P(y|x)P(x)}{P(y)}$$

- 我们无需从对 $P(y|q)$ 的认知开始, 因为

$$P(y|q) = \sum_x P(y|xq)P(x|q)$$

注释

- 该公式以托马斯·贝叶斯牧师命名, 他最先发现了该公式的一个特殊情况。
- 此处呈现的通用版本由皮埃尔-西蒙·拉普拉斯独立发现。



已知

$$p(x|q) = \mathcal{N}(x|\mu, \Lambda^{-1}q)$$

$$p(y|x,q) = \mathcal{N}(y|Ax+b, L^{-1}q)$$

我们有

$$p(y|q) = \mathcal{N}(y|A\mu+b, L^{-1} - A\Lambda^{-1}A^T) q$$

$$p(x|\Sigma t A^T L p y) = \mathcal{N}(x|\Lambda\mu, \Sigma q)$$

其中

$$\Sigma = \Lambda - A^T L A^{-1}$$