



西安电子科技大学
XIDIAN UNIVERSITY

现代机器学习

机器学习（双语）

杨莉 (liy@xidian.edu.cn)

西安电子科技大学人工智能学院


2025年5月



卷积神经网络 #1

- 图像处理网络
- 不变性与等变性
- 一维卷积
- 卷积层
- 通道
- 感受野
- 用于MNIST一维数据的卷积网络



图像分类




- 多类分类问题（离散类别，可能类别数>2）
- 卷积神经网络



物体检测



图像分割



- 多变量二元分类问题（多个输出，两个离散类别）
- 卷积编码器-解码器网络

图像网络

- 图像具有三项特性，表明需要专门的模型架构。
- **首先**，图像具有高维特性。典型分类任务中的图像包含 224×224 个RGB值（即150,528个输入维度）。
- 全连接网络中的隐藏层通常大于输入尺寸，因此即使对于浅层网络，权重数量也会超过 $150,528^2$ ，即220亿。这在**所需训练数据、内存和计算资源**方面带来明显实践难题。



图像网络

■ **其次**，相邻图像像素在统计学上存在关联性。

■ 然而，全连接网络不存在“邻近”的概念，而是将所有输入之间的关系一视同仁。

■ 若训练图像与测试图像的像素均被随机置换，网络仍可正常训练且无实质差异。

■ **第三**，图像的解释在几何变换下保持稳定。

■ 将树木图像向左平移几个像素后，它依然是树木图像。

■ 然而这种位移会改变网络接收的所有输入。因此全连接模型必须在每个位置单独学习代表树木的像素模式，这显然效率低下。



卷积神经网络

- 卷积层独立处理**图像**的每个**局部区域**，使用共享于整张图像的**参数**。
- 它们使用的**参数**比全连接层少，能利用**相邻像素之间的空间关系**，且无需在每个位置重新学习像素的解释。
- 主要由卷积层组成的网络称为卷积神经网络（CNN）。



卷积网络

- 图像网络
- 不变性与等变性
- 一维卷积
- 卷积层
- 通道
- 感受野
- 用于MNIST一维数据的卷积网络

- 我们在上文论证过，图像的某些特性（如树木纹理）在变换下保持稳定。本节将使这一概念进行更严谨的数学阐述。

不变性

- 若函数 $f[x]$ 对变换 $t[x]$ 具有不变性，则满足：

$$f[t[x]] = f[x]$$

即函数输出在变换后保持不变。

不变性示例

例如：图像分类

- 图像已被转换，但我们希望分类器给出相同的结果



- 网络 $f[x]$ 应能识别图像中包含**相同**物体，即使该图像已被平移、旋转、翻转或变形。



等变性

- 若函数 $f[x]$ 对变换 $t[]$ 具有等变性，则需满足：

$$f[t[x]] = t[f[x]]$$

即输出与输入经历相同变换

等变性示例

例如：图像分割

- 图片已完成翻译，我们希望分割内容同步翻译



卷积神经网络

- 图像处理网络
- 不变性与等变性
- 一维卷积
- 卷积层
- 通道
- 感受野
- 用于MNIST的卷积网络1D

一维卷积*

- 输入向量 $\mathbf{x}$:

$$\mathbf{x} = [x_1, x_2, \dots, x_I]$$

- 输出为邻域加权和:

$$z_i = \omega_1 x_{i-1} + \omega_2 x_i + \omega_3 x_{i+1}$$

- 卷积核或滤波器:

$$\boldsymbol{\omega} = [\omega_1, \omega_2, \omega_3]^T$$



核尺寸=3

* 严格来说并非卷积


卷积核尺寸为3的卷积

- 若平移输入 x ，则对应输出 z 将以相同方式平移。

a)




b)



对输入平移的等变性


$$f[t[x]] = t[f[x]]$$

零填充



将超出输入末端的位置视为零。

“有效”卷积




仅处理卷积核完全落在图像内的位置（输出尺寸较小）。



步长、核尺寸与膨胀

- 步长 = 每次输出向后移位 k 个位置
 - 相对于输入缩小输出规模
- 核尺寸 = 为每个输出赋予不同数量的输入权重
 - 整合更大区域的信息
 - 但增大卷积核尺寸会导致权重数量增加
- 膨胀卷积或空洞卷积 = 在卷积核值间插入零值
 - 整合更大区域的信息
 - 参数更少



图。步长、核尺寸与膨胀。a) 当步长为2时，我们每隔一个位置评估核函数，因此第一个输出 z_1 由以 x_1 为中心的加权和计算得出；b) 第二个输出 z_2 由以 x_3 为中心的加权和计算得出，依此类推。c) 核尺寸也可调整。当核尺寸为五时，我们对最近的五个输入进行加权求和。d) 在膨胀卷积或空洞卷积中，我们在权重向量中插入零值，从而能够用更少的权重整合大范围区域的信息。



卷积网络

- 图像网络
- 不变性与等变性
- 一维卷积
- 卷积层
- 通道
- 感受野
- 用于MNIST的卷积网络1D

卷积层

- 卷积层通过对输入进行卷积运算，添加偏置项 β ，并将每个结果通过激活函数 $a[\cdot]$ 处理来计算输出。
- 当卷积核尺寸为3、步长为1、膨胀率为1时，第 i 个隐藏单元 h_i 的计算方式如下：

$$\begin{aligned} h_i &= a[\beta + \omega_1 x_{i-1} + \omega_2 x_i + \omega_3 x_{i+1}] \\ &= a\left[\beta + \sum_{j=1}^3 \omega_j x_{i+j-2}\right] \end{aligned}$$

全连接网络的特例

■ 卷积网络：

$$\begin{aligned} h_i &= a [\beta + \omega_1 x_{i-1} + \omega_2 x_i + \omega_3 x_{i+1}] \\ &= a \left[\beta + \sum_{j=1}^3 \omega_j x_{i+j-2} \right] \end{aligned}$$



← 3 个权重，1 个偏置项

■ 全连接网络：



$$h_i = a \left[\beta_i + \sum_{j=1}^D \omega_{ij} x_j \right]$$

← D^2 个权重，D 个偏置项

全连接网络的特例





全连接网络



卷积，尺寸3，步长1，

膨胀因子1，零填充




卷积，尺寸3，步长2，膨胀1，零填

充

问题1


- 卷积核尺寸?
- 步长?
- 膨胀?
- 零填充/有效填充?



	x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8
h_1								
h_2								
h_3								
h_4								
h_5								
h_6								
h_7								
h_8								

问题2


- 核大小?
- 步长?
- 膨胀?
- 零填充/有效填充?



	x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8
h_1	■	■	■	□	□	□	□	□
h_2	□	■	■	■	□	□	□	□
h_3	□	□	■	■	■	□	□	□
h_4	□	□	□	■	■	■	□	□
h_5	□	□	□	□	■	■	■	□
h_6	□	□	□	□	□	■	■	■

问题 3

- 核大小?
- 步长?
- 膨胀?
- 零填充/有效填充?



	x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8
h_1	Dark Brown	White	Light Brown	White	White	White	White	White
h_2	White	Dark Brown	White	Light Brown	White	White	White	White
h_3	Black	White	Dark Brown	White	Light Brown	White	White	White
h_4	White	Black	White	Dark Brown	White	Light Brown	White	White
h_5	White	White	Black	White	Dark Brown	White	Light Brown	White
h_6	White	White	White	Black	White	Dark Brown	White	Light Brown
h_7	White	White	White	White	Black	White	Dark Brown	White
h_8	White	White	White	White	White	Black	White	Dark Brown



卷积网络


- 图像网络
- 不变性与等变性
- 一维卷积
- 卷积层
- 通道
- 感受野
- 用于MNIST一维数据的卷积网络



通道


- 若仅执行单次卷积，信息必然会丢失；
- 我们正在对邻近输入进行取平均值操作，而ReLU激活函数会对小于零的结果进行截断。
- 因此通常会**并行**计算多个卷积操作。每次卷积都会生成一组新的隐藏变量，称为**特征图**或**通道**。

一个输出通道，一个输入通道




一个输入通道，两个输出通道，

a)




b)



两个输入通道，一个输出通道

c)





有多少个参数？

- 若存在 C_i 个输入通道且核尺寸为 K

$$\Omega \in \mathbb{R}^{C_i \times K}$$

$$\beta \in \mathbb{R}$$

- 若存在 C_i 个输入通道和 C_o 个输出通道

$$\Omega \in \mathbb{R}^{C_i \times C_o \times K}$$

$$\beta \in \mathbb{R}^{C_o}$$




卷积网络

- 图像网络
- 不变性与等变性
- 一维卷积
- 卷积层
- 通道
- 感受野
- 用于MNIST一维数据的卷积网络


感受野

- 网络中隐藏单元的**感受野**是原始输入区域，该区域向其提供输入。
- 考虑一个卷积网络，其中每个卷积层的卷积核尺寸为三。第一层的隐藏单元对三个最近输入进行加权求和，因此其**感受野尺寸**为三。




感受野

- 第二层的单元对第一层中距离最近的三个位置进行加权求和，而这些位置本身也是三个输入的加权和。因此，第二层隐藏单元的感受野大小为五。






感受野





感受野





卷积网络

- 图像网络
- 不变性与等变性
- 一维卷积
- 卷积层
- 通道
- 感受野
- 用于MNIST一维数据的卷积网络

MNIST 1D数据集

Original MNIST examples





图 MNIST-1D.

- a) 10个类别的模板 $y \in \{0, \dots, 9\}$, 基于数字0-9。
- b) 训练样本 x 通过随机变换模板并添加噪声生成。
- c) 添加噪声生成。
- d) 随后在40个垂直位置采样变换后模板的水平偏移量。改编自(Greydanus, 2020)

卷积网络

- 四个隐藏层
- 三个卷积层
- 一个全连接层
- 末端采用Softmax层
- 总参数数 = 2050
- 采用SGD训练100,000步，学习率 $LR = 0.01$ ，批量大小100

MNIST-1D卷积神经网络







全连接网络

- 完全相同的层数和隐藏单元数
- 所有全连接层
- 总参数数 = 150,185

性能



为什么？

- 更优的归纳偏差
- 强制网络对每个位置进行相同处理
- 在不同位置间共享信息
- 在更小的输入/输出映射家族中进行搜索，所有映射均具有合理性



卷积 #2

- 二维卷积
- 下采样与上采样, 1×1 卷积
- 图像分类
- 物体检测
- 语义分割



二维卷积

- 前一节介绍了用于处理一维数据的卷积网络。
- 此类网络可应用于金融时间序列、音频和文本处理。
- 然而，卷积网络更常用于二维数据处理。
图像数据。卷积核现在是一个二维对象。

二维卷积

- 二维卷积
 - 对 $K \times K$ 区域进行加权求和
 - $K \times K$ 权重矩阵
- 通过添加偏置项并经激活函数处理构建卷积层

$$h_{i,j} = a \left[\beta + \sum_{m=1}^3 \sum_{n=1}^3 \omega_{m,n} x_{i+m-2,j+n-2} \right]$$

其中 $\omega_{m,n}$ 为卷积核的元素。

这本质上是对 **3×3 输入区域** 的加权求和。

二维卷积




图2. 二维卷积层。每个输出 h_{ij} 通过计算3×3最近邻输入的加权和，添加偏置项，并经激活函数处理后输出结果。

结果通过激活函数处理。

a) 此处输出 h_{23} （阴影输出）是 x_{12} 至 x_{34} 九个位置（阴影输入）的加权和。

b) 不同的输出由计算得出
通过在图像网格上二维平移核函数获得。

c-d) 采用零填充时，图像边缘外的位置视为零。



二维卷积中的通道

- 输入通常为RGB图像，其被视为具有三个通道的二维信号。
- 在此，一个 3×3 卷积核将包含 $3 \times 3 \times 3$ 个权重，并应用于二维卷积的三个输入通道，在每个 3×3 位置进行操作，从而生成与输入图像高度和宽度相同的二维输出图像（假设采用零填充）。



二维卷积中的通道

- 为生成多个输出通道，我们使用不同核权重重复此过程，并将结果拼接成**3D张量**。

二维卷积中的通道

- 若核函数尺寸为 $K \times K$ ，且存在 C_i 个输入通道，则每个输出通道**均为** $C_i \times K \times K$ 个量值的加权和加上一个偏置项。

$$\omega \in \mathbb{R}^{C_i \times K \times K} \qquad \beta \in \mathbb{R}$$

- 由此可知，计算 C_o 个输出通道时，**需要** $C_i \times C_o \times K \times K$ 个权重系数个权重和 C_o 个偏置量。

$$\omega \in \mathbb{R}^{C_i \times C_o \times K \times K} \qquad \beta \in \mathbb{R}^{C_o}$$




图2D卷积应用于图像的示意图。图像被视为**具有三个通道的二维输入**，分别对应红、绿、蓝三色分量。采用 3×3 卷积核时，第一隐藏层的每个预激活值通过以下步骤计算：将 $3 \times 3 \times 3$ 卷积核权重与同位置的 3×3 RGB图像块进行逐点乘法运算，求和后加上偏置项。为计算隐藏层所有预激活值，我们将卷积核在图像上进行"滑动"操作

图像进行水平与垂直方向的滑动。输出结果为隐藏单元的二维层。若需生成多通道输出通道时，需使用多个核重复此过程，最终在 H_1 隐藏层生成隐藏单元的三维张量。




卷积 #2

- 二维卷积
- 下采样与上采样, 1×1 卷积
- 图像分类
- 物体检测
- 语义分割



MNIST-1D卷积网络






下采样与上采样

- 该网络通过在每层使用步长为二的卷积缩小表示，从而**增加了感受野的大小**。
- 现探讨缩减二维输入表示的方法。
- 同时阐述了将其重新放大的方法（**上采样**），当输出同样是图像时此方法尤为实用。
- 最后探讨层间通道数调整方法，该技术在合并网络双分支表示时尤为有效。

下采样


- 缩小二维表示主要有三种方法。这里我们考虑最常见的情况：将两个维度都缩小两倍。
- 首先，我们可以**对每隔一个位置进行采样**。当步长为2时，我们实际上是在卷积操作的同时应用这种方法（图a）。



隔位采样（等效于步长为2）


下采样

- 其次, **最大池化**保留2x2输入值中的最大值(图b)。这引入了平移不变性; 若输入位移一个像素, 多数最大值仍保持不变。
- 最后, **均值池化**或**平均池化**对输入进行平均处理。
- 对于所有方法, 我们分别对每个通道进行下采样, 因此输出图像的宽度和高度减半, 但通道数保持不变。







上采样

- 将网络层放大以实现分辨率翻倍的最简方法, 是在每个空间位置将所有通道**复制四次** (图a)。
(如图a所示)。
- 第二种方法是**最大池化反向操作**; 当先前采用最大池化进行降采样时, 可将值重新分配至原始位置 (图b)。
- 第三种方法采用**双线性插值**填补点位间缺失值, 即在已采样点之间进行插值计算。
有样本。(图c)。



上采样

- 第四种方法大致类似于步长为二的下采样。
- 该方法中输出数量为输入的一半，当核尺寸为三时，每个输出都是三个最近输入的加权和（图a）。
- 在**转置卷积**中，这种情况发生了逆转（图c）。
- 输出数量是输入的两倍，每个输入都对三个输出产生贡献。
- 当我们考察这种上采样机制的关联权重矩阵（图 d）时，发现它正是下采样机制矩阵（图 b）的转置。




1x1卷积

- 有时我们希望在两个隐层之间**改变通道数量**而不进行进一步的空间池化操作。这样做通常是为了将该表示与另一个并行计算结果进行组合。
表示与另一并行计算结果。
- 为实现此目的，我们应用**核尺寸为1的卷积操作**。输出层的每个元素
输出层的每个元素都通过计算同一位置所有通道的加权和来生成。
位置的加权求和。
- 我们可以使用不同的权重重复此操作多次，以生成所需数量的输出通道。相关的卷积权重尺寸为 $1 \times 1 \times C_i \times C_o$ 。
- 因此，这种**卷积**被称为**1x1卷积**。结合偏置项和激活函数，它相当于在每个位置对所有通道运行相同的全连接网络。
所有通道上运行相同的全连接网络。



1×1卷积



- 混合通道
- 可改变通道数
- 相当于在每个位置运行相同的全连接网络



卷积 #2

- 二维卷积
- 下采样与上采样, 1×1 卷积
- 图像分类
- 物体检测
- 语义分割



图像分类


- 图像分类的目标是将图像分配到预先确定的类别之一。



ImageNet数据库

- 计算机视觉领域深度学习的许多开创性工作都聚焦于使用ImageNet数据集进行图像分类。
- 该数据库包含
 - 1,281,167张训练图像，
 - 50,000张验证图像，
 - 以及100,000张测试图像。
 - 每张图像都被标记为属于1000个可能类别中的一个。


ImageNet数据库



图示。ImageNet分类示例图像。该模型旨在将输入图像分配至1000个类别之一。此任务具有挑战性，因为图像在不同属性（列）上存在显著差异。这些属性包括：刚性（猴子 < 划艇）、图像中实例数量（蜥蜴 < 草莓）、杂乱程度（指南针 < 钢桶）、尺寸（蜡烛 < 蜘蛛网）、纹理（螺丝刀 < 豹纹）、色彩独特性（马克杯 < 红酒）以及形状独特性（海岬 < 铃铛）。改编自 Russakovsky 等人的研究（2015）。(2015)研究改编。


AlexNet (2012)

- 在 2011 年，在深度网络应用之前，最先进的方法对测试图像的分类**错误率约为 25%**，正确类别位于**前五名建议中**。五年后，最好的深度学习模型超越了人类的表现。
- 2012年，**AlexNet**成为首个在此任务上表现优异的卷积神经网络。
 - 该网络包含**八个**采用ReLU激活函数的**隐藏层**，其中前五个层为**卷积层**，其余为**全连接层**。




AlexNet (2012)

- 完整的网络包含约6000万个参数。其中大部分位于全连接层和网络末端。
- 测试阶段采用动量系数0.9、批量大小128的梯度下降算法，对图像的五种裁剪与镜像版本进行平均结果计算，并应用L2（权重衰减）正则化。
- 该系统实现了16.4%的前五名错误率和38.1%的首位错误率。



- 数据增强采用2048倍的空间变换和输入强度修改。





- 全连接层应用了Dropout技术



VGG (2015)

- VGG网络同样针对ImageNet任务的分类问题进行优化，实现了显著提升的性能：**前五名错误率为6.8%**，第一名错误率为23.7%。
- 该网络同样由一系列交错的卷积层和最大池化层组成，其中表示的空间尺寸逐渐减小，但通道数量增加。随后是三个全连接层。
VGG网络采用
通道数逐渐增加。其后接续三个全连接层。VGG网络
同样采用了数据增强、权重衰减和dropout技术进行训练。
- AlexNet与VGG之间最重要的变化在于**网络深度**。后者采用**19个隐藏层**和**1.44亿个参数**。





Year



卷积 #2

- 二维卷积
- 下采样与上采样, 1×1 卷积
- 图像分类
- 物体检测
- 语义分割


物体检测

- 在物体检测中，目标是在图像中**识别和定位多个物体**。
- 基于卷积网络的早期方法是**You Only Look Once**（简称**YOLO**）。
- YOLO网络的输入为448×448像素的RGB图像。
- 该图像经过24层卷积层处理，这些层通过最大池化操作逐步缩小表示尺寸，同时增加通道数量（类似于VGG网络）。最终卷积层尺寸为7×7，具有1024个通道。该层输出被重塑为向量，全连接层将其映射为目标检测结果。

通道数量，其机制与VGG网络类似。最终卷积层尺寸为7×7且拥有1024个通道。该层经重塑为向量后，通过全连接层映射至4096个值。另一全连接层将此表示映射该表示映射至最终输出。


YOLO

- 输出值编码了**7×7网格中每个位置**存在的类别（图a-b）。
- 对于每个位置，输出值还编码了固定数量的**边界框**。每个边界框由五个参数定义：中心点的x和y坐标、边界框的高度和宽度以及预测置信度（图c）。
- 置信度用于评估预测边界框与真实边界框之间的重叠程度。
- 该系统采用动量、权重衰减、dropout和数据增强进行训练。
- 采用**迁移学习**策略：网络首先在ImageNet分类任务上进行预训练，随后针对目标检测任务进行微调。





YOLO

- 网络运行后，通过**启发式**过程移除置信度较低的矩形框，并抑制预测的边界框与同一物体对应的情况
物体的预测边界框，仅保留置信度最高的边界框。






结果



迁移学习



从ImageNet分类任务中迁移学习



卷积 #2

- 二维卷积
- 下采样与上采样, 1×1 卷积
- 图像分类
- 物体检测
- 语义分割


语义分割


-
- Diagram illustrating the U-Net architecture for medical image segmentation. The network consists of an encoder (left) and a decoder (right), connected by skip connections (green).
- Encoder (Left):**
- Input: 224 × 224 × 3 image.
 - Stage 1: Conv 3 × 3, MaxPool. Output: 112 × 112 × 128.
 - Stage 2: Conv 3 × 3, MaxPool. Output: 56 × 56 × 256.
 - Stage 3: Conv 3 × 3, MaxPool. Output: 28 × 28 × 512.
 - Stage 4: Conv 3 × 3, MaxPool. Output: 14 × 14 × 512.
 - Stage 5: MaxPool + FC. Output: 4096.
- Decoder (Right):**
- Stage 6: MaxUnPool. Output: 7 × 7 × 512.
 - Stage 7: Deconv 3 × 3, MaxUnPool. Output: 14 × 14 × 512.
 - Stage 8: Deconv 3 × 3, MaxUnPool. Output: 28 × 28 × 512.
 - Stage 9: Deconv 3 × 3, MaxUnPool. Output: 56 × 56 × 256.
 - Stage 10: Deconv 3 × 3, MaxUnPool. Output: 112 × 112 × 128.
 - Stage 11: Deconv 3 × 3, MaxUnPool. Output: 224 × 224 × 3.
- Output:** The final output is a segmented image showing the tumor region (green) and the rest of the image (black).



语义分割 (2015)

- 网络的第一部分是VGG的精简版，包含13个卷积层（而非15个），并将表示缩小至14×14尺寸。随后进行增加一次最大池化操作，随后通过两个全连接层映射至两个维度为4096的1D表示。
- 这些层不表示空间位置，而是**整合整幅图像的信息**。






■ 网络的下采样侧有时被称为**编码器**，上采样侧则称为**解码器**，因此这类网络因其形状常被称为**编码器-解码器网络**或**沙漏网络**。

[illegible]

语义分割（2015）

- 最终分割结果通过启发式方法生成，该方法采用贪婪搜索策略寻找类
推断其区域，采取考虑考虑该
不仅涉及概率计算，更注重促进关联性。最且
- 随后添加次高频类别的元素，填充其在剩余
未标注像素区域占据主导地位。此过程持续进行，直至证据不足以添加更多类别。





总结

- 卷积层中，每个隐藏单元通过对邻近输入进行加权求和、添加偏置项并应用激活函数来计算。
- 权重和偏置在每个空间位置保持恒定，因此相较于全连接网络，其**参数数量大幅减少**，且参数数量不会随输入图像尺寸增加。
- 为确保信息不丢失，该操作会使用不同的权重和偏置重复执行，从而在每个空间位置创建多个通道。



总结

- 典型的卷积网络由卷积层与降采样层交替组成，降采样层将数据尺寸缩小一半。
- 随着网络的推进，空间维度通常以2的倍数递减，通道数则以2为倍数递增。
- 在网络末端，通常存在一个或多个全连接层，这些层整合来自整个输入的信息并生成所需的输出。
- 若输出为图像，则镜像化的“解码器”会将其重新上采样至原始尺寸。



总结

- 卷积层的平移不变性赋予了有用的归纳偏置，相较于全连接网络，这能提升基于图像任务的性能网络。
- 我们描述了图像分类、目标检测和语义分割网络。随着网络深度增加，图像分类性能得到提升。但后续实验表明，网络深度无限增加并非持续有益——超过特定深度后，系统将难以训练。这正是残差连接的研发动因。